Jezikovne tehnologije

6. junij 2024

Borko Bošković, Jani Dugonik, Klemen Berkovič, Janez Brest

O predmetu

Predmet

- Jezikovne tehnologije
- ECTS točke: 6
- Predavatelj: doc. dr. Borko Bošković (borko.boskovic@um.si)
- Več informacij: `https://estudij.um.si/`

Vsebina

- Uvod
  - Pregled jezikovnih tehnologij in osnovno procesiranje jezika
- Modeliranje jezika
  - Verjetnostni jezikovni modeli, ocenjevanje modelov in metode glajenja
- Popravljanje pravopisa
  - Besedne in nebesedne pravopisne napake, šumni kanal
- Klasifikacija besedil
  - Metode klasificiranja besedil in ocenjevanje metod klasificiranja
- Analiza sentimenta
  - Osnovne metode analize sentimenta in leksikoni sentimenta
- Semantika in WordNet
  - Strukture za opis semantike, interpretacija semantike, pomen
- Statistično strojno prevajanje
  - Metode in ocenjevanje strojnega prevajanja
- Ekstrakcija informacij in prepoznavanje imenskih entitet
- Napredne jezikovne tehnologije
  - Globoko učenje, vektorji besed

Jezikovne tehnologije

- Cilj:
  - Osnovni principi procesiranja naravnega jezika
  - Uporaba jezikovnih tehnologj.
- Znanja in razumevanje:
  - Opisati smernice razvoja za procesiranje naravnega jezika,
  - opisati več standardnih metod, ki jih uporabljamo v sistemih za procesiranje naravnega jezika za opis morfologije in sintakse,
  - izkazati razumevanje pomembnosti pragmatike pri razumevanju naravnega jezika,
  - razumeti in izkazati znanje o različnih metodologijah, ki jih najdemo pri procesiranju naravnega jezika, in
  - kako te metodologije uporabiti v različnih aplikacijah.
- Usmeritve:
  - Samostojnost in
  - individualnost.

Način ocenjevanja

- Laboratorijske vaje 50 %
  - Seminarska naloga 50 %
  - Naloge 50 %
- 1. vmesni izpit 25 %
- 2. vmesni izpit 25 %
- Pozitivno opravljena vmesna izpita:
  - Povprečna uspešnost nad 50 % in vsak posamezno nad 35 %.
- Če študent ni pozitivno opravil vmesnih izpitov, jih nadomesti s pisnim izpitom v deležu 50 %.

Literatura

- C. D. Manning, H. Schütze: Foundations of statistical natural language processing, Sixth Edition, MIT Press, Cambridge,2003.
- P. Jackson, I. Moulinier: Natural Language Processing for Online Applications: Text Retrieval, Extraction, and Categorization, Second Edition, John Benjamins, cop., Amsterdam, 2007.
- Daniel Jurafsky and James H. Martin. Speech and Language Processing, 2nd edition. Pearson Prentice Hall, 2008.
- Steven Bird, Ewan Klein in Edward Loper. Natural Language Processing with Python. O'Reilly Media, 2009.
- Philipp Koehn, Statistical Machine Translation, Cambridge University Press, 2010
- Li Deng and Yang Liu. Deep Learning in Natural Language Processing, 1st edition, Springer, 2018

Spletni viri

- Slovenska raziskovalna infrastruktura za jezikovne vire in tehnologije
  `http://www.clarin.si/info/o-projektu/`
- Slovensko društvo za jezikovne tehnologije:
  `http://www.sdjt.si/SDJT.html`
- Statistical natural language processing and corpus-based computational linguistics: An annotated list of resources:
  `http://www-nlp.stanford.edu/links/statnlp.html`
- European Language Resources Association:
  `http://www.elra.info/`
- Sistem za vaje:
  `https://estudij.um.si/`

Pregled jezikovnih tehnologij

(angl. Overview of Natural Language Processing)

Računalniška obdelava naravnega jezika

- Računsko jezikoslovje (angl. *Computational Linguistics*)
  - Veja računalništva in informatike, ki se navezuje na jezikoslovje.
  - Cilj: modeliranje naravnega jezika za različne računalniške aplikacije (črkovalniki, prevajalniki, lematizatorji itd.).
- Jezikovne tehnologije (JT) (angl. *Language Technologies*)
  - Skupek tehnologij, ki so namenjena procesiranju naravnega jezika.
  - Računalnik uporablja naravni jezik kot vhodno izhodni tok podatkov.
  - Računalniški jeziki $\leftrightarrow$ računalnik : naravni jezik $\leftrightarrow$ računalnik razumevanje naravnega jezika (angl. *Natural Language Understanding*)
  - angl. *Natural Language Processing* - NLP
  - angl. *Human Language Technology* - HLT

Google Prevajalnik

- Jezikovne tehnologije so namenjena samodejnemu procesiranju naravnega jezika.
- Language technologies are designed to automatically process natural language.
- Jezikovne tehnologije so zasnovane tako, da samodejno obdelujejo naravni jezik.

Naravni jezik

- Predstavlja nepogrešljivo orodje za komunikacijo med ljudmi.
- Za človeka je preprost, računalnikom povzroča preglavice.
- Jezik je živ in se spreminja skozi čas.
- Različni jeziki se med seboj lahko zelo razlikujejo.
- Problemi, ki izstopajo pri jezikovnih tehnologijah
  - Večpomenskost: mnoge besede imajo več pomenov.
    gori na gori gori
  - Parafraze: mnoge vsebine je mogoče izraziti na več načinov.
    nafta $\rightarrow$ *črna kri industrijskega sveta*
    kača $\rightarrow$ *nevarna plazilka*
  - Nedoločenost: mnoga jezikovna sredstva imajo nedoločen pomen, ki ga razberemo šele iz sobesedila.
  - Metafora: je raba besedne zveze namesto druge na podlagi kake njune skupne pomenske lastnosti.
    Denar je sveta vladar.

Strukturalistični in empirični vidiki jezikoslovja

- Strukturalistični pristop:
  - Jezik je omejen in urejen sistem, ki temelji na pravilih.
  - Avtomatska obdelava jezika je mogoča s pomočjo pravil.
  - Pravila se oblikuje v skladu s človeško jezikovno intuicijo.
- Empirični pristop:
  - Jezik je vsota vseh svojih udejanjanj (v govorjenih in pisnih besedilih)
  - Posplošitve o jeziku so mogoče le na podlagi velikih besedilnih zbirk, ki nam služijo kot **vzorec** jezika $\rightarrow$ **korpusi**
  - Strojno učenje (angl. *Machine Learning*):
    - "data-driven automatic inference of rules"

Raziskovalna področja

- Oblikoslovje: besednovrstno označevanje (angl. *part-of-speech tagging*), lematizacija, razčlemba sestavljenih besed
- Skladnja: razpoznavanje stavčnih členov, slovničnih funkcij (osebek/povedek/...); popolna skladenjska analiza
- Glasoslovje: razpoznavanje in tvorjenje govora, pogovorni sistemi
- Pomenoslovje: razreševanje večpomenskosti, avtomatska izdelava semantičnih virov (tezavrov, ontologij)
- Večjezikovne tehnologije: luščenje ustreznic iz korpusov, strojno prevajanje in tolmačenje
- Jezik in internet: iskanje podatkov, rudarjenje besedil (angl. *Text Mining*), napredni spletni iskalniki

Aplikacije

- Cilj je razumevanje naravnih jezikov. To vključuje tudi govorjenje in pisanje v naravnih jezikih.
- Aplikacije: urejevalnik besedil, elektronski slovar, črkovalniki, slovnični pregledovalniki, sintetizator govora, razpoznavalnik govora, razpoznavalnik tekstovnega besedila, prevajalnik naravnih jezikov itd.
- Delitev glede na podatkovne vire:
  - Tekstovni viri (knjige, spletne strani, poročila, elektronska pošta, podnapisi filmov itd.)
  - Dialog oz. komunikacija s človekom.

Aplikacije - tekstovni jezikovni viri

- Poiskati ustrezno besedilo, ki pripada določni tematiki (spletno stran, knjigo itd.).
- Olajšati vnos besedila, zaradi vrste naprave ali telesnih hib.
  - Najbolj prodajana aplikacija za Android v letu 2012 je bila **SwiftKey**.
- Izluščiti določene informacije iz besedila ali članka, ki pripada določenemu področju (npr. športne novice o nogometaših).
- Prevajanje dokumentov iz enega v drug jezik (npr. prevajanje spletnih strani).
- Podajanje povzetka določenega besedila (npr. 3 stransko poročilo 100 stranskega dokumenta).

Aplikacije, ki komunicirajo s človekom.

- Sistemi vprašanj in odgovorov (angl. *Question-answering systems*), kjer naravni jezik predstavlja povpraševalni jezik.
- Samodejni telefonski servis (npr. naročanje izdelkov iz kataloga).
- Učni sistem, kjer je računalnik v interakciji s študenti (npr. učni sistem za matematiko).
- Krmiljenje stroja ali računalnika s pomočjo glasa.
- Sistem za reševanje splošnih problemov (npr. sistem za pomoč pri načrtovanju in razporejanju opravil).

Viri

- Špela Vintar, FF, ULJ, 2006
- Janez Brest, FERI, MB, 2012
- T. Erjavec; IJS: `http://nl.ijs.si/et/teach/mps10-hlt/`
- Wikipedija
  - `http://en.wikipedia.org/wiki/Natural_language_processing`
  - `http://en.wikipedia.org/wiki/Computational_linguistics`
- P. Jackson, I. Moulinier: Natural Language Processing for Online Applications: Text Retrieval, Extraction, and Categorization, Second Edition, John Benjamins, cop., Amsterdam, 2007.
- Language Technology World: `http://www.lt-world.org`
- Natural Language Toolkit: `http://www.nltk.org`

Osnovno procesiranje besedila

(angl. Basic Text Processing)

Regularni izrazi

- Formalen jezik za opis niza znakov.
- Kako najdemo skupino besed (npr.: Hiša, hiša, Hiše, hiše, Hiši, hiši, Hišica, hišica)?
- Kaj pa naslednje besedilo:
  Primož pa Petra potujeta po poročnem potovanju. Potem pa pof, prelepo potovanje postane problem. Pretresena, prašna, prešvicana pririneta pred petrolovo postojanko. Prijazen prodajalec ponudi pomoč "potrebujeta pomoč". Petra predlaga Primožu pogledati po petrolovi prodajalni. Povsod polne prodajne police. Popravljeno, pokliče prodajalec. Pa Primož pa Petra ponovno potujeta po poročnem potovanju.

Regularni izrazi

- [A-z], [0-9], [^a-z] ...
- a | b , Ab | cD, ...
- [Hh](iša | išica)
- Hišk?a
- To+, Go+I, Nee*
- Hiš.
- ^[Pp].+
- \.$
- V besedilu poiščite vse veznike ”in“.

Regularni izrazi - napake

Dva tipa napak:

- Ujemanje z nezaželenimi nizi znakov.
- Zaželene nize znakov ne razpoznamo.

Slovarji

- “Gori na gori gori.”
- Koliko besed?
  - 3 besede ali 2 besedi?
  - 4 tipov besed ali 2 tipa besed?
- Google N-grams: 10^{12} besed in $13 * 10^6$ tipov besed.
  `https://catalog.ldc.upenn.edu/LDC2006T13`

Enostavni leksikalni analizator

- $ time ‘cat jrc-acquis.sl | tr -sc ’A-Za-z’ ’\n’ | sort | uniq -c | sort -rn > frekvence1.txt‘
  real 0m55.666s
  user 0m59.478s
  sys 0m0.901s
- $ time ‘cat jrc-acquis.sl | sed s/[^A-Za-zČŠŽčšž]/*n*/g | sort | uniq -c | sort -rn > frekvence2.txt‘
  real 0m45.020s
  user 0m46.727s
  sys 0m2.888s
- The JRC-Acquis Multilingual Parallel Corpus
  `https://ec.europa.eu/jrc/en/language-technologies`
- Europarl: A Parallel Corpus for Statistical Machine Translation
  `http://www.statmt.org/europarl/`
- Katere besede se najpogosteje uporabljajo?

Frekvence besed

$ head frekvence1.txt

- 741954 in
- 690527 v
- 616613 za
- 437074 je
- 396580 na
- 363879 ki
- 347304 se
- 289553 z
- 245837 o
- 224690 da

$ head frekvence2.txt

- 719929 in
- 687614 v
- 545570 za
- 412470 je
- 345747 se
- 340045 ki
- 327220 na
- 289014 z
- 232087 o
- 224558 da

Problemi leksikalnih analizatorjev

- Različna pravila za različne jezike
- Krajši zapis besed (npr.: oz. $\leftrightarrow$ oziroma)
- Velike in male črke (npr: Gori na gori gori.)
- Posebni znaki (npr.: ČŠŽčšž)
- Smer pisanja besedila
- Delimiterji oz. ločilni znaki
  - Algoritem maksimalnega ujemanja (npr. v kitajščini in japonščini)

Normalizacija besedila

- Skoraj vsak program jezikovnih tehnologij izvaja normalizacijo besedila.
- Leksikalna analiza oz. segmentacija besed
- Normalizacija formatov besed
- Segmentacija povedi

Normalizacija besedila

- Iskanje informacij (angl. *Information Retrieval*)
  - Indeksiranje besedila
  - Povpraševanje po izrazih mora imeti določeno obliko
- Implicitna definicija sorodnih izrazov
  - npr.: tj. $\leftrightarrow$ To je; itd. $\leftrightarrow$ in tako dalje
- Razširitve
  - npr.: Miza $\leftrightarrow$ miza, mize, Mizi, mizica
- Zmogljivejši algoritem / manjša učinkovitost / večja kompleksnost

Preslikava velikih v male črke

- *Case folding*
- Aplikacije, ki se ukvarjajo z iskanjem informacij, spreminjajo velike v male črke.
- Izjeme/problemi:
  - npr.: Prekmurska gibanica, Pomurka
- Analiza sentimenta, strojno prevajanje, ekstrakcija informacij
  - Razlikovanje velikih in malih črk je koristno

Lematizacija (geslenje)

- Lematizacija predstavlja korak v normalizaciji besedila, kjer so pregibne besedne oblike v besedilu, npr. mize ali mizi, poenotene na svojo lemo. Te leme se nato lahko uporabljajo pri leksikalni analizi besedil, npr. kot iskalna funkcija konkordančnikov, avtomatski gradnji leksikonov, pri strojnem prevajanju, itd.
- Osnovno obliko besede imenujemo lema
- Krnjenje besed ne preoblikuje besede v njihovo slovarsko obliko, ampak besedam zgolj odreže končnico.
- hodim, hodiš, hodita, hodimo $\leftrightarrow$ lema: hoditi, krn: hodi
- Leksem je kombinacija leme z besedno vrsto.
- Lematizacija je iskanje pravilne slovarske osnovne oblike besede.
- Uporabno pri strojnem prevajanju.

Morfologija

- Veda, ki preučuje tvorbo besed, tipe besed in njihove oblike.
- Morfem - najmanjša pomenska enota oz. najmanjši del besede, ki ima svoj pomen.
- Male smiselne enote, ki tvorijo besede.
  - Jedro besede
  - Razširitve besed (ponavadi slovnične)

Segmentacija povedi

- Kje je konec povedi?
- Znaki ki končujejo povedi: “?”, “!” in “.”.
- Izjeme “npr.”, “dr.”.
- Uporaba klasifikatorjev.
  - Ročno ugotavljanje (piki sledi velika začetnica, dolžina besede pred piko itd.).
  - Odločitvena drevesa.
  - Nevronske mreže.

Viri

- Dan Jurafsky, Chris Manning, Natural Language Processing
- Sašo Džeroski, Tomaž Erjavec, Strojno učenje lematizacije neznanih slovenskih besed, Odsek za inteligentne sisteme, Institut "Jožef Stefan", Jamova 39, 1000 Ljubljana

Razdalja urejanja

(angl. Edit Distance)

Kako podobna sta si dva niza znakov?

- Uporablja se za črkovanje, strojno prevajanje, razpoznavanje govora itd.
- Katera beseda je najbolj podobna besedi jezik:
  - jezikoslovje
  - ježiček
  - jez
- Problem poravnave nizov.
  - lopar_____
  - ___parazit

Razdalja urejanja

- Minimalna razdalja urejanja med dvema nizoma (angl. *Minimum Edit Distance*).
- Najmanjše število operacij urejanja.
  - Vstavljanje (angl. *Inserton*)
  - Brisanje (angl. *Deletion*)
  - Zamenjava (angl. *Substitution*)
- Koliko operacij je potrebnih, da spremenimo en niz znakov v drugega?

Minimalna razdalja urejanja

- `samodejnost`
- `samostojnost`
- `--zzb---`
- Cena vsake operacije je ena $\Rightarrow$ razdalja je 3 (Levenshtein).
- Cena zamenjave je 2 $\Rightarrow$ razdalja je 5.

Uporabnost razdalje urejanja

- Ocenjevanje strojnega prevajanja in razpoznave govora.
- Pri strojnem prevajanju se izračuna razlika urejanja besed med stavkom strojnega prevajanja in stavkom, ki ga je prevedel človek.
- Pri razpoznavanju govora ugotavljamo razliko urejanja besed med stavkom, ki ga je govorec povedal in stavkom, ki ga je računalnik razpoznal.

Določanje minimalne razlike urejanja

- Iskanje zaporedja operacij urejanja, da iz začetnega niza znakov dobimo želeni niz znakov.
  - Začetno stanje (beseda, ki jo transformiramo).
  - Operacije: vstavljanje, brisanje, zamenjava.
  - Ciljno stanje: beseda, ki jo iščemo.
  - Cena poti: število operacij urejanja.
- Drevo preiskovanja

Minimalna razdalja urejanja

- Velikost prostora vseh sekvenc urejanja je ogromna.
- Naivna ali požrešna metoda je nesprejemljiva.
- Dosti različnih poti najde isto besedo.
  - Ne želimo slediti vsem možnim potem.
  - Zanimajo nas le najkrajše poti.

Minimalna razdalja urejanja

- Imamo dva niza znakov X in Y,
- Dolžina nizov V_x in V_y.
- Razdalja med nizoma je D_{V_x,V_y}.
  - Razdalja med podnizi: $D_{i,j}$; $i \in \{1, ..., V_x\}, j \in \{1, ..., V_y\}$.

Dinamično programiranje

- *Dynamic programming*
- Dinamično programiranje - končna rešitev je sestavljena iz komponent rešitve oz. iz delnih rešitev. Ko na tekočem koraku ugotovimo, da delna rešitev oz. komponenta neke rešitve ne vodi h cilju, to delno rešitev zavržemo.
- 2D polje razdalj.
- Problem rešujemo s pomočjo rešitev podproblemov.
- Metoda od spodaj navzgor (angl. *Bottom-up*).
  - Izračunamo D(i,j) za male i,j.
  - Za večje se izračuna glede na rezultate manjših (i,j).
  - Izračunamo D(i,j) za vse vrednosti i in j (i $\in \{0, ..., V_x\}$; j$\in \{0, ..., V_y\}$).

Razdalja urejanja

- Izračunajte razdaljo urejanja za naslednji besedi: Windows in Linux.

Algoritem za minimalno razdaljo urejanja

for i = 0 to V_x **do**
  D[i,0] = i;
end for
for j = 0 to V_y **do**
  D[0,j] = j
end for
for i = 1 to V_x **do**
  for j = 1 to V_y **do**

$$D[i,j] = min \begin{cases} D[i-1,j]+1 \\ D[i,j-1]+1 \\ D[i-1,j-1] + \begin{cases} 2, & X[i] \; != \; Y[j] \\ 0, & X[i] \; == \; Y[j] \end{cases} \end{cases}$$

  end for
end for

Algoritem za minimalno razdaljo urejanja

	/	s	a	m	o	s	t	o	j	n	o	s	t
/	0	1	2	3	4	5	6	7	8	9	10	11	12
s	1												
a	2												
m	3												
o	4												
d	5												
e	6												
j	7												
n	8												
o	9												
s	10												
t	11												

$$D[i,j] = min \begin{cases} D[i-1,j]+1 \\ D[i,j-1]+1 \\ D[i-1,j-1] + \begin{cases} 2, & X[i] \; != \; Y[j] \\ 0, & X[i] \; == \; Y[j] \end{cases} \end{cases}$$

Algoritem za minimalno razdaljo urejanja

	/	s	a	m	o	s	t	o	j	n	o	s	t
/	0	1	2	3	4	5	6	7	8	9	10	11	12
s	1	0	1	2	3	4	5	6	7	8	9	10	11
a	2	1	0	1	2	3	4	5	6	7	8	9	10
m	3	2	1	0	1	2	3	4	5	6	7	8	9
o	4	3	2	1	0	1	2	3	4	5	6	7	8
d	5	4	3	2	1	2	3	4	5	6	7	8	9
e	6	5	4	3	2	3	4	5	6	7	8	9	10
j	7	6	5	4	3	4	5	6	5	6	7	8	9
n	8	7	6	5	4	5	6	7	6	5	6	7	8
o	9	8	7	6	5	6	7	6	7	6	5	6	7
s	10	9	8	7	6	5	6	7	8	7	6	5	6
t	11	10	9	8	7	6	5	6	7	8	7	6	5

Primer

Prikažite način delovanja algoritma za računanje razdalje urejanja za besedi Linux in Windows.

Poravnava nizov

- Razdalja urejanja nam ponavadi ne zadošča.
  - Zanima nas kako poravnati dve besedi oz. katere operacije urejanja je potrebno narediti, da spremenimo en niz v drugega.
- S pregledovanjem poti vračanja ugotovimo, katere operacije so potrebne.
- Glede na smer gibanja in vrednosti razdalje ugotavljamo operacije.

Poravnava nizov

	/	s	a	m	o	s	t	o	j	n	o	s	t
/	0 -	1	2	3	4	5	6	7	8	9	10	11	12
s	1	0 -	1	2	3	4	5	6	7	8	9	10	11
a	2	1	0 -	1	2	3	4	5	6	7	8	9	10
m	3	2	1	0 -	1	2	3	4	5	6	7	8	9
o	4	3	2	1	0 -	1 V	2	3	4	5	6	7	8
d	5	4	3	2	1	2	3 Z	4	5	6	7	8	9
e	6	5	4	3	2	3	4	5 Z	6	7	8	9	10
j	7	6	5	4	3	4	5	6	5 -	6	7	8	9
n	8	7	6	5	4	5	6	7	6	5 -	6	7	8
o	9	8	7	6	5	6	7	6	7	6	5 -	6	7
s	10	9	8	7	6	5	6	7	8	7	6	5 -	6
t	11	10	9	8	7	6	5	6	7	8	7	6	5-

Algoritem poravnave nizov

for i = 0 to V_x **do**
    D[i,0] = i;
end for
for j = 0 to V_y **do**
    D[0,j] = j
end for
for i = 1 to V_x **do**
    for j = 1 to V_y **do**

$$D[i,j] = min \begin{cases} D[i-1,j]+1 \\ D[i,j-1]+1 \\ D[i-1,j-1] + \begin{cases} 2, & X[i] \; != \; Y[j] \\ 0, & X[i] \; == \; Y[j] \end{cases} \end{cases}$$

$$kazalec(i,j) = \begin{cases} levo & \rightarrow vstavljanje \\ gor & \rightarrow brisanje \\ diagonalno & \rightarrow zamenjava \end{cases}$$

    end for
end for

Primer

Prikažite način delovanja algoritma za računanje poravnave za besedi Linux in Windows.

Zahtevnost algoritma

- Časovna zahtevnost: $O(n \cdot m)$.
- Prostorska zahtevnost: $O(n \cdot m)$.
- Ugotavljanje operacij urejanja: $O(n + m)$.

Utežena razdalja urejanja

- Določene operacije so pri določenih opravilih in črkah verjetnejše.
- Črkovalnik.
  - Razporeditev tipk na tipkovnici.
  - Naravni jezik, ki ga uporabljamo (frekvenca znakovnih bigramov).

Minimalna razdalja urejanja z utežmi

D[0,0] = 0;
for i = 0 to V_x **do**
  D[i,0] = D[i-1,0]+brisanje(x[i]);
end for
for j = 0 to V_y **do**
  D[0,j] = D[0,j-1]+vstavljanje(y[j]);
end for
for i = 1 to V_x **do**
  for j = 1 to V_y **do**

$$D[i,j] = min \begin{cases} D[i-1,j] + brisanje(x[i]) \\ D[i,j-1] + vstavljanje(y[j]) \\ D[i-1,j-1] + zamenjava(x[i], y[j]) \end{cases}$$

  end for
end for

Vir

- Dan Jurafsky, Chris Manning, Natural Language Processing
  `http://web.stanford.edu/~jurafsky/NLPCourseraSlides.html`

Jezikovni modeli

(angl. Language Models)

Verjetnostni jezikovni model

- Zaporedju besed dodeljuje verjetnosti.
  - Strojno prevajanje (angl. *Machine Translation*) - katera poved ima večjo verjetnost, glede na jezikovni model?
  - Preverjanje pravopisnih napak (angl. *Spelling Correction*) - kako ena beseda spremeni verjetnost povedi?
  - Razpoznavanje govora (angl. *Speech Recognition*) - z uporabo verjetnostnega modela izboljša učinkovitost razpoznavanja.
  - Uporabno tudi na drugih področjih jezikovnih tehnologij (npr. povzemanje besedila, sistem vprašanj in odgovorov).

Kako izračunamo verjetnosti

- $P(dan|danes\ je\ lep) = \frac{\text{število}(danes\ je\ lep\ dan)}{\text{število}(danes\ je\ lep)}$
- Preveč povedi in možnosti za tak izračun.
- Potrebna enormna količina podatkov.
- Potrebna je alternativa.
  - $P(dan|danes\ je\ lep) \approx P(dan|lep)$
  - $P(dan|danes\ je\ lep) \approx P(dan|je\ lep)$
- Markova predpostavka.
  - $P(b_1\ b_2\ b_3\ \ldots\ b_n) \approx \prod_i P(b_i|b_{i-k}\ \ldots\ b_{i-1})$
  - $P(b_i|b_1\ b_2\ b_3\ \ldots\ b_{i-1}) \approx P(b_i|b_{i-k}\ \ldots\ b_{i-1})$

N-grami

- Uporabimo lahko trigrame, štirigrame in petgrame.
  - Trigrami: $P(b_i|b_1\ b_2\ b_3\ \ldots\ b_{i-1}) \approx P(b_i|b_{i-2}b_{i-1})$
  - Štirigrami: $P(b_i|b_1\ b_2\ b_3\ \ldots\ b_{i-1}) \approx P(b_i|b_{i-3}b_{i-2}b_{i-1})$
  - Petgrami: $P(b_i|b_1\ b_2\ b_3\ \ldots\ b_{i-1}) \approx P(b_i|b_{i-4}b_{i-3}b_{i-2}b_{i-1})$
- V splošnem je to model jezika, ki ni popoln.
  - Jezik ima daljše odvisnosti.
- Iz praktičnih razlogov uporabimo logaritme.
  - $log(p_1 \cdot p_2 \cdot p_3 \cdot p_4) = log(p_1) + log(p_2) + log(p_3) + log(p_4)$
  - Izognemo se malim vrednostim.
  - Seštevanje je hitrejše od množenja.
- Cenilka po metodi največjega verjetja (angl. *Maximum Likelihood Estimate*).

$$P(b_i|b_{i-1}) = \frac{\text{število}(b_{i-1},b_i)}{\text{število}(b_{i-1})}\ ; \qquad P(b_i) = \frac{\text{število}(b_i)}{\sum_{b_j \in V} \text{število}(b_j)}$$

- Orodje za jezikovno modeliranje: SRILM `http://www.speech.sri.com/projects/srilm/`.

Kako dober je jezikovni model?

- Ali model daje prednosti dobrim ali slabim povedim?
- Dodeli večje verjetnosti “realnim” oz. “zelo pogostim” povedim ali “nepravilnim”, ki se ne pojavljajo pogosto?
- Model naučimo na učni množici (angl. *Training set*).
- Model preizkusimo na še ne videnih podatkih.
  - Testna množica (angl. *Test set*) so ne videni podatki, ki se razlikujejo od učne množice.
  - Metrike (angl. *Evaluation metric*) ocenijo kako dobro se je naš model izkazal na testni množici.

Zunanje ovrednotenje n-gram modelov

- Primerjava modela A in B.
  - Vsak od modelov opravi svojo nalogo.
    - Črkovanje, razpoznavanje govora, strojno prevajanje.
  - Določanje uspešnosti modela A in B.
    - Število napačno črkovanih besed.
    - Število napačno prevedenih besed.
  - Primerjava uspešnosti modelov A in B.

Zunanje ovrednotenje n-gram modelov

- Je časovno zahtevno - lahko traja dneve ali tedne.
- Uporabimo notranje ovrednotenje oz. perpleksnost (angl. *Perplexity*).
  - Slabi približki.
    - Uporabimo učno množico kot testno množico.
    - Daje oceno, ki nam lahko nekaj pove o modelu.
    - Primerno za začetne eksperimente.

Perpleksnost

- Boljši model daje boljšo napoved ne videne povedi.
- Perpleksnost je inverz verjetnosti testne množice, ki je normaliziran s številom besed.

$$PP(S) = P(b_1\ b_2\ b_3\ \ldots\ b_n)^{-\frac{1}{n}} = \sqrt[n]{\frac{1}{P(b_1\ b_2\ b_3\ \ldots\ b_n)}}$$

$$PP(S) = \sqrt[n]{\prod_{i=1}^{n} \frac{1}{P(b_i \mid b_1\ b_2\ b_3\ \ldots\ b_{i-1})}}$$

- Trigrami

$$PP(S) = \sqrt[n]{\prod_{i=1}^{n} \frac{1}{P(b_i \mid b_{i-2}\ b_{i-1})}}$$

- Maksimiranje verjetnosti je enako kot minimizacija perpleksnosti.

Perpleksnost kot povprečni vejitveni faktor

- Koliko možnosti imamo v povprečju, da nadaljujemo poved?
- Imejmo "poved", ki jo definira naslednji regularni izraz: [0-9]+.
- Kakšna je perpleksnost glede na model pri katerem je verjetnost pojavitve določene števke $\frac{1}{10}$?
  $PP(S) = P(b_1 b_2 b_3 .... b_n)^{-\frac{1}{n}} = ((\frac{1}{10})^n)^{-\frac{1}{n}} = (\frac{1}{10})^{-1} = 10$
- Manjša perpleksnost pomeni boljši model.

Nevarnosti prekomernega prilagajanja

- angl. *overfitting*
- Modeli, ki temeljijo na n-gramih, delujejo dobro v primerih ko je testna množica podobna učni množici.
- V splošnem se testna množica razlikuje od učne mnižice.
- Problem so ne videni podatki - podatki, ki se ne pojavljajo v učni množici in jih najdemo v testni množici.
  - $P(dan \mid danes\ je\ lep) = 0$
  - Ni možno izračunati perpleksnosti (deljenje z 0).
- Potrebujemo bolj robusten model.

Glajenje Add-one (Laplace)

- Glajenje (angl. *Smoothing*).
- Zamislimo si, da smo vsako besedo videli enkrat več, kot smo jo dejansko videli.
- Enostavno vsakemu števcu dodamo 1.
- Cenilka po metodi največjega verjetja (angl. *Maximum Likelihood Estimate*):

$$P_{MLE}(b_i|b_{i-1}) = \frac{\text{število}(b_{i-1},b_i)}{\text{število}(b_{i-1})}; \quad P_{MLE}(b_i) = \frac{\text{število}(b_i)}{\sum_{b_j \in V} \text{število}(b_j)}$$

- Verjetnostna ocena z glajenjem Laplace:

$$P_{Add-one}(b_i) = \frac{\text{število}(b_i)+\mathbf{1}}{\sum_j (\text{število}(b_j)+1)} = \frac{\text{število}(b_i)+\mathbf{1}}{\mathbf{N}+\mathbf{V}}$$

$$P_{Add-one}(b_i|b_{i-1}) = \frac{\text{število}(b_{i-1},b_i)+\mathbf{1}}{\text{število}(b_{i-1})+\mathbf{V}}$$

- Ni primerno za modele, ki temeljijo na n-gramih (imamo ogromno "ne videnih" podatkov).
- Uporablja se za druge modele jezikovnih tehnologij.
  - Klasifikacija besedila.
  - V domenah kjer ni dosti "ne videnih podatkov".

Primer za besedni bigram

Besedilo:
I want to see a movie.
I love chocolate cake with vanilla cream.
I have to wake up early in the morning.
Microsoft and delays go together like ice cream and apple pie.
They have the best ice cream in town.
Their creamy milk is made into a delicious ice cream.

Katera poved je bolj verjetna?

- ☐ I have to go to sleep.
- ☐ I want ice cream.

Primer za besedni bigram

- Povedi najprej predprocesiramo tako, da odstranimo vsa ločila (vejice, pike, klicaje, itd.) in posebne znake, in spremenimo vse velike črke v male črke.
- Ker računamo besedne bigrame, je potrebno na začetku in na koncu povedi dodati znak za začetek <s> oz. konec povedi </s>.
- To naredimo zato, da izračunamo, kolikokrat se beseda pojavi na začetku ali na koncu povedi.

Primer za besedni bigram

Predprocesirano besedilo:

<s>i want to see a movie</s>
<s>i love chocolate cake with vanilla cream</s>
<s>i have to wake up early in the morning</s>
<s>microsoft and delays go together like ice cream and apple pie</s>
<s>they have the best ice cream in town</s>
<s>their creamy milk is made into a delicious ice cream</s>
$V = 40$

Katera poved je bolj verjetna?
<s>i have to go to sleep</s>
<s>i want ice cream</s>

Primer za besedni bigram

$$P(\text{<s> i have to go to sleep </s>}) = \frac{4}{46} \cdot \frac{2}{43} \cdot \frac{2}{42} \cdot \frac{1}{42} \cdot \frac{1}{41} \cdot \frac{1}{42} \cdot \frac{1}{40}$$
$$= 6.7e^{-11}$$
$$P(\text{i} \mid \text{<s>}) = \frac{3+1}{6+40} = \frac{4}{46}$$
$$P(\text{have} \mid \text{i}) = \frac{1+1}{3+40} = \frac{2}{43}$$
$$P(\text{to} \mid \text{have}) = \frac{1+1}{2+40} = \frac{2}{42}$$
$$P(\text{go} \mid \text{to}) = \frac{0+1}{2+40} = \frac{1}{42}$$
$$P(\text{to} \mid \text{go}) = \frac{0+1}{1+40} = \frac{1}{41}$$
$$P(\text{sleep} \mid \text{to}) = \frac{0+1}{2+40} = \frac{1}{42}$$
$$P(\text{</s>} \mid \text{sleep}) = \frac{0+1}{0+40} = \frac{1}{40}$$

Primer za besedni bigram

$P(\text{<s> i want ice cream </s>}) = \frac{4}{46} \cdot \frac{2}{43} \cdot \frac{1}{41} \cdot \frac{4}{43} \cdot \frac{3}{44} = 6.3e^{-7}$

$\text{<s> i} = P(\text{i} \mid \text{<s>}) = \frac{3+1}{6+40} = \frac{4}{46}$

$\text{i want} = P(\text{want} \mid \text{i}) = \frac{1+1}{3+40} = \frac{2}{43}$

$\text{want ice} = P(\text{ice} \mid \text{want}) = \frac{0+1}{1+40} = \frac{1}{41}$

$\text{ice cream} = P(\text{cream} \mid \text{ice}) = \frac{3+1}{3+40} = \frac{4}{43}$

$\text{cream </s>} = P(\text{</s>} \mid \text{cream}) = \frac{2+1}{4+40} = \frac{3}{44}$

$P(\text{<s> i have to go to sleep </s>}) = 6.7e^{-11}$

$P(\text{<s> i want ice cream </s>}) = 6.3e^{-7}$

Večjo verjetnost ima poved "I want ice cream".

Naloga za besedni bigram

nogomania.com:

Ronaldo veliki junak trilerja.
Messi rešil Barcelono.
Ronaldo zabija več kot klubi.
Ronaldo noče oditi.
Lahko zabijam kot Messi in Ronaldo.
Ronaldo bo postal gostinec.
Messi in Higuain kot majhni punčki.

Katera poved je bolj verjetna?
Messi je najboljši.
Ronaldo je najboljši.

Naloga za besedni bigra

Predprocesirano besedilo:

<s>ronaldo veliki junak trilerja</s>
<s>messi rešil barcelono</s>
<s>ronaldo zabija več kot klubi</s>
<s>ronaldo noče oditi</s>
<s>lahko zabijam kot messi in ronaldo</s>
<s>ronaldo bo postal gostinec</s>
<s>messi in higuain kot majhni punčki</s>
$V = 24$

Katera poved je bolj verjetna?
<s>messi je najboljši</s>
<s>ronaldo je najboljši</s>

Izračun

$P(\text{<s> messi je najboljši </s>}) = \frac{3}{31} \cdot \frac{1}{27} \cdot \frac{1}{24} \cdot \frac{1}{24} = 6.22e^{-6}$
$P(\text{messi} \mid \text{<s>}) = \frac{2+1}{7+24} = \frac{3}{31}$
$P(\text{je} \mid \text{messi}) = \frac{0+1}{3+24} = \frac{1}{27}$
$P(\text{najboljši} \mid \text{je}) = \frac{0+1}{0+24} = \frac{1}{24}$
$P(\text{</s>} \mid \text{najboljši}) = \frac{0+1}{0+24} = \frac{1}{24}$

$P(\text{<s> ronaldo je najboljši </s>}) = \frac{5}{31} \cdot \frac{1}{28} \cdot \frac{1}{24} \cdot \frac{1}{24} = 1e^{-5}$
$P(\text{ronaldo} \mid \text{<s>}) = \frac{4+1}{7+24} = \frac{5}{31}$
$P(\text{je} \mid \text{ronaldo}) = \frac{0+1}{4+24} = \frac{1}{28}$
$P(\text{najboljši} \mid \text{je}) = \frac{0+1}{0+24} = \frac{1}{24}$
$P(\text{</s>} \mid \text{najboljši}) = \frac{0+1}{0+24} = \frac{1}{24}$

Večjo verjetnost ima poved "Ronaldo je najboljši".

Izračun z uporabo logaritma

$$\log(P(\text{<s>messi je najboljši</s>})) =$$
$$log\,\tfrac{3}{31} + log\,\tfrac{1}{27} + log\,\tfrac{1}{24} + log\,\tfrac{1}{24} = -5,2$$

$$\log(P(\text{<s>ronaldo je najboljši</s>})) =$$
$$log\,\tfrac{5}{31} + log\,\tfrac{1}{28} + log\,\tfrac{1}{24} + log\,\tfrac{1}{24} = -5$$

"Backoff" in interpolacija

- V primeru neznanih besednih zvez uporabimo informacije manjših besednih zvez.
- "Backoff"
  - Uporabimo trigrame, če imamo primerne podatke
  - v nasprotnem uporabimo bigrame in
  - na koncu uporabimo unigrame.
- Interpolacija
  - Kombinacija unigramov, bigramov in trigramov
  - Interpolacija daje boljše rezultate

Linearna interpolacija

- Enostavna interpolacija
  $\hat{P}(b_n|b_{n-2}b_{n-1}) =$
  $\lambda_1 P(b_n|b_{n-2}b_{n-1}) + \lambda_2 P(b_n|b_{n-1}) + \lambda_3 P(b_n)$
  $\sum_i \lambda_i = 1$
- Interpolacija odvisna od vsebine
  $\hat{P}(b_n|b_{n-2}b_{n-1}) = \lambda_1(b_{n-2}^{n-1})P(b_n|b_{n-2}b_{n-1}) +$
  $\lambda_2(b_{n-2}^{n-1})P(b_n|b_{n-1}) + \lambda_3(b_{n-2}^{n-1})P(b_n)$

Primer enostavne interpolacije

- <s> jaz sem janez </s>
- <s> janez je moje ime </s>
- <s> priimka pa ne povem, sem skrivnosten </s>
- Kakšna je verjetnost P(janez|jaz sem), če vzamemo $\lambda_i = \frac{1}{3}$?
- P(janez|jaz sem) $= \frac{1}{3} \cdot \frac{2}{19} + \frac{1}{3} \cdot \frac{1}{2} + \frac{1}{3} \cdot \frac{1}{1}$

Kako nastaviti λ_i?

- Učna množica (učni korpus)
- Razvojna množica (angl. Held-Out set) - uporablja se za nastavljanje meta parametrov
- Testna množica (testni korpus)
- Izberemo take vrednosti za λ_i, da maksimiramo verjetnosti za razvojno množico
  - Ugotovimo verjetnosti n-gramov (učna množica)
  - Iščemo vrednosti λ_i, ki dajejo največjo verjetnost za razvojno množico: $\log P(b_1 ... b_n | M(\lambda_1 ... \lambda_k)) = \sum_i \log P_{M(\lambda_1 ... \lambda_k))}(b_i | b_{i-1})$

Neznane besede?

- Poznamo vse besede vnaprej
  - Fiksna dolžina slovarja
- Ponavadi vseh besed ne poznamo vnaprej
  - Dolžina slovarja ni znana
- Ustvarimo neznani leksikalni simbol (angl. *Unknown Token*) <UNK>
  - Učenje verjetnosti <UNK>
    - Ustvarimo leksikon L fiksne dolžine V
    - Pri normalizaciji besedila, vsako neznano besedo, ki ni v slovarju zamenjamo z <UNK>
    - Nato ugotavljamo njene verjetnosti enako kot pri ostalih besedah
  - Faza dekodiranja
    - Za vse neznane besede uporabimo verjetnosti besed <UNK>

Ogromni spletni n-grami

- Kako obravnavamo ogromne korpuse n-gramov?
- Klestenja (angl. *Pruning*)
  - Shranimo le tiste n-grame katerih število je večje od določenega praga
  - Klestenje na osnovi entropije
- Učinkovitost
  - Učinkovite podatkovne strukture kot so npr. drevesa
  - Približni jezikovni modeli
  - Shranjevanje besed s pomočjo indeksov (Huffmanovo kodiranje)
  - Predstavitev verjetnosti - števila predstavimo z manj biti (npr. 4 - 8)

Glajenje namenjeno spletnim n-gramom

- "Stupid backoff" (Brants in ostali 2007)
- Enostavno uporabimo relativne frekvence

$$S(b_i|b_{i-k+1}^{i-1}) = \begin{cases} \frac{\text{število}(b_{i-k+1}^{i})}{\text{število}(b_{i-k+1}^{i-1})} & \text{če število}(b_{i-k+1}^{i}) > 0 \\ 0{,}4S(b_i|b_{i-k+2}^{i-1}) & \text{drugače} \end{cases}$$

$$S(b_i) = \frac{\text{število}(b_i)}{N}$$

Glajenje n-gramov

- Glajenje ”Add-1“
  - Primerno za klasifikacijo dokumentov, ni primerno za jezikovne modele
- Najbolj uporabljene metode uporabljajo interpolacijo
- Za velike korpuse se uporablja ”Stupid backoff“

Napredni jezikovni modeli

- Diskriminatorni modeli
  - Uporablja uteži n-gramov in se ne prilagaja učni množici
- Model temelječ na razpoznavanju (angl. *Parsing-based models*)
- Model, ki uporablja predpomnjenje
  - Besede, ki so se pred kratkim uporabile imajo večjo verjetnost pojavitve

$$P_{pred}(b|zgodovina) = \lambda P(b_i|b_{i-2}b_{i-1}) + (1+\lambda)\frac{\text{število}(b \in zgodovina)}{|zgodovina|}$$

  - Daje slabe rezultate pri razpoznavanju govora

Posplošitev glajenja "Add - 1"

- Glajenje "Add - 1":
  - $P_{Add-1}(b_i|b_{i-1}) = \frac{\text{število}(b_{i-1},b_i)+1}{\text{število}(b_{i-1})+V}$
- Glajenje "Add - k":
  - $P_{Add-k}(b_i|b_{i-1}) = \frac{\text{število}(b_{i-1},b_i)+k}{\text{število}(b_{i-1})+k\cdot V}$
  - $P_{Add-k}(b_i|b_{i-1}) = \frac{\text{število}(b_{i-1},b_i)+m\frac{1}{V}}{\text{število}(b_{i-1})+m}$
- Glajenje "Unigram prior":
  - $P_{\text{UnigramPrior}}(b_i|b_{i-1}) = \frac{\text{število}(b_{i-1},b_i)+m\cdot P(b_i)}{\text{število}(b_{i-1})+m}$

Napredni algoritmi glajenja

- Temeljijo na intuiciji
  - Good-Turing
  - Kneser-Ney
  - Witten-Bell
- V izračunih uporabljajo stvari, ki so videne le enkrat
  - Pomagajo ovrednotiti stvari, ki niso bile videne

Glajenje "Good-Turing"

- N_c - število stvari, ki se je ponovilo c-krat
- Za rojstni dan ste dobili naslednja darila:
  10 x čokolada, 5 x šampanjec, 2 x pivo, **1 x vino, 1 x knjiga, 1 x ura**
- Kakšna je verjetnost, da naslednji gost prinese vino?

Glajenje "Good-Turing"

- N_c - število stvari, ki se je ponovilo c-krat
- Za rojstni dan ste dobili naslednja darila:
  10 x čokolada, 5 x šampanjec, 2 x pivo, **1 x vino, 1 x knjiga, 1 x ura**
- Kakšna je verjetnost, da naslednji gost prinese vino?
  - $\frac{1}{20}$

Glajenje "Good-Turing"

- N_c - število stvari, ki se je ponovilo c-krat
- Za rojstni dan ste dobili naslednja darila:
  10 x čokolada, 5 x šampanjec, 2 x pivo, **1 x vino, 1 x knjiga, 1 x ura**
- Kakšna je verjetnost, da naslednji gost prinese vino?
  - $\frac{1}{20}$
- Kakšna je verjetnost, da naslednji gost prinese darilo, ki se bo razlikovalo od prejšnjih?
  - Uporabimo informacije, ki so se ponovile 1x

Glajenje "Good-Turing"

- N_c - število stvari, ki se je ponovilo c-krat
- Za rojstni dan ste dobili naslednja darila:
  10 x čokolada, 5 x šampanjec, 2 x pivo, **1 x vino, 1 x knjiga, 1 x ura**
- Kakšna je verjetnost, da naslednji gost prinese vino?
  - $\frac{1}{20}$
- Kakšna je verjetnost, da naslednji gost prinese darilo, ki se bo razlikovalo od prejšnjih?
  - Uporabimo informacije, ki so se ponovile 1x
  - $\frac{3}{20}$ ($N_1 = 3$)

Glajenje "Good-Turing"

- P^*_{GT}(unigrami z ničelno frekvenco) $= \frac{N_1}{N}$
- Za nevideno stvar:
  - c $= 0$
  - $MLE = \frac{0}{20} = 0$
  - $P^*_{GT} = \frac{3}{20}$
- $c^* = \frac{(c+1)N_{c+1}}{N_c}$ (za ne ničelno frekvenco)
- $P^*_{GT} = \frac{c^*}{N}$
- Za uro:
  - c $= 1$
  - $MLE = \frac{1}{20}$
  - $c^* = \frac{(c+1)N_{c+1}}{N_c} = \frac{2 \cdot N_2}{N_1} = \frac{2 \cdot 1}{3} = \frac{2}{3}$
  - $P^*_{GT}(ura) = \frac{\frac{2}{3}}{20} = \frac{1}{30}$
- P^*_{GT}(n-grami z ničelno frekvenco) $= \frac{c^*}{N}$
  N_0 ocenimo. Npr. za bigrame $N_0 = V * V - N^b$
  N^b - število unikatnih bigramov

Problemi glajenja "Good-Turing"

- Koliko je P^*_{GT} za najbolj pogosto besedo korpusa?
- Problem nastopi pri besedah, ki se zelo pogosto pojavljajo
- Za male k velja $N_k > N_{k+1}$
- Za velike k, imamo velike skoke in ničelne ocene.
- Rešitev: vrednosti problematičnih empiričnih N_k se nadomestijo z vrednostmi določene prilagoditvene funkcije

Števila pri glajenju "Good-Turing"

- Povzeto iz: Church in Gale (1991)

Števec c	Good Turing c^*
0	0,0000270
1	0,446
2	1,26
3	2,24
4	3,24
5	4,22
6	5,19
7	6,21
8	7,24
9	8,25

- Zdi se, da je $c^* = c - 0,75$

Prihranek s pomočjo interpolacije

- Prihranimo nekaj časa s preprostim odštevanjem 0,75 ali neko vrednostjo d!
  $P_{prihranek} = (b_i|b_{i-1}) = \frac{število(b_{i-1},b_i)-d}{število(b_{i-1})} + \lambda(b_{i-1})P(b)$
- $\lambda(b_{i-1})$ je interpolacijska utež.
- Mogoče je vseeno potrebno imeti določene posebne vrednosti d za manjše vrednosti števcev.
- Ali res moramo uporabiti običajni P za unigrame?

Glajenje Kneser-Ney

- Boljše ocenjevanje verjetnosti unigramov, ki se manjkrat pojavijo.
  - Beseda "sobota" je bolj splošna kot beseda "krila".
  - Toda verjetnost, da besedi "Murska" sledi "Sobota", je zelo velika.
- Unigrami so uporabni v primeru, ko določenega bigrama nismo videli.
- Namesto verjetnosti $P(b)$ (kako verjetna je beseda b), uporabimo verjetnost $P_{nadaljevanja}(b)$ (kako verjetna je beseda b, kot nadaljevanje nečesa).
  $P_{nadaljevanja}(b) \propto |\{b_{i-1} : število(b_{i-1}, b) > 0\}|$

Glajenje Kneser-Ney

- Kolikokrat se je beseda b pojavila kot nadaljevanje nečesa:
  $P_{nadaljevanja}(b) \propto |\{b_{i-1} : število(b_{i-1}, b) > 0\}|$
- Normalizacija s številom vseh bigramov:
  $|\{(b_{j-1}, b_j) : število(b_{j-1}, b_j) > 0\}|$

$$P_{nadaljevanja}(b) = \frac{|\{b_{i-1} : število(b_{i-1}, b) > 0\}|}{|\{(b_{j-1}, b_j) : število(b_{j-1}, b_j) > 0\}|}$$

Glajenje Kneser-Ney

Za bigrame:

$$P_{KN} = (b_i|b_{i-1}) = \frac{max(število(b_{i-1}, b_i) - d, 0)}{število(b_{i-1})} + \lambda(b_{i-1}) P_{nadaljevanja}(b_i)$$

$\lambda(b_{i-1})$ je normalizirana konstanta:

$$\lambda(b_{i-1}) = \frac{d}{število(b_{i-1})} |\{b : število(b_{i-1}, b) > 0\}|$$

Glajenje Kneser-Ney

Rekurzivna enačba:

$$P_{KN}(b_i|b_{i-n+1}^{i-1}) = \frac{max(\check{s}t_{KN}(b_{i-n+1}^{i}) - d, 0)}{\check{s}t_{KN}(b_{i-n+1}^{i-1})} + \lambda(b_{i-n+1}^{i-1})P_{KN}(b_i|b_{i-n+2}^{i-1})$$

$$\check{s}t_{KN}(\bullet) = \begin{cases} \check{s}tevilo(\bullet) & za\ višje\ stopnje\ n\text{-}gramov \\ \check{s}tevilo_{nadaljevanja}(\bullet) & za\ n\text{-}grame\ 1.\ stopnje \end{cases}$$

$\check{s}tevilo_{nadaljevanja}$ je število unikatnih samostojnih besed v kontekstu z $\bullet$. Način izračuna je prikazan na enem od prejšnjih slajdov.

Viri

- Dan Jurafsky, Chris Manning, Natural Language Processing `http://web.stanford.edu/~jurafsky/NLPCourseraSlides.html`
- Mirjam Sepesy Maučec, Statistično jezikovno modeliranje pri razpoznavanju govora, Center za interdisciplinarne in multidisciplinarne raziskave in študije, Univerza v Mariboru, Razlagova 22, 2000 Maribor, Slovenija

Popravljanje pravopisa

(angl. Spelling Correction)

Pravopisne naloge

- Zaznavanje pravopisnih napak
- Popravljanje pravopisnih napak
  - Samodejno popravljanje (an $\rightarrow$ na)
  - Predlaganje popravka
  - Predlaganje seznama popravkov

Tipi pravopisnih napak

- Nebesedne napake (angl. *non-word errors*)
  - marma $\rightarrow$ karma
- Besedne napake (angl. *real-word errors*)
  - Tipografske napake (angl. *typographical erros*)
    - praksa $\rightarrow$ praska
  - Kognitivne napake (angl. *cognitive errors*)
    - rob $\rightarrow$ rop
    - trk $\rightarrow$ trg

Nebesedne pravopisne napake

- angl. *non-word spelling errors*
- Zaznavanje nebesednih pravopisnih napak
  - vsaka beseda, ki ni v slovarju, je napaka
  - večji je slovar, boljše je
- Popravljanje nebesednih pravopisnih napak
  - Ustvarimo kandidatke $\rightarrow$ to so pravilne besede, ki so podobne napačni besedi
  - Izberemo tisto, ki je najboljša:
    - Najkrajša razdalja urejanja z utežmi
    - Največja verjetnost šumnega kanala

Šumni kanal (angl. *Noisy channel*)

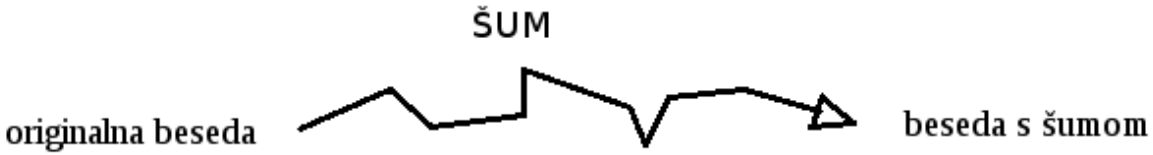

x - napačno črkovana beseda

Poiščemo pravilno besedo b:

$$\hat{b} = \arg\max_{b \in V} P(b \mid x) = \arg\max_{b \in V} \frac{P(x \mid b)P(b)}{P(x)} = \arg\max_{b \in V} P(x \mid b)P(b)$$

Generiranje kandidatk

Na dva načina:

- Besede s podobnim črkovanjem
- Besede s podobno izgovorjavo
- 80% napak je na razdalji urejanja 1
- Skoraj vse napake so na razdalji urejanja 2
- Dovoljuje vstavljanje presledkov in stičnih vezajev
  - pridisem → pridi sem
  - črnobelo → črno-belo

Damerau-Levenshtein razdalja urejanja

Imamo besedo *plot* in nekaj primerov besed z razdaljo 1:

- Transpozicija (angl. *Transposition*): p**ol**t → p**lo**t
- Vstavljanje (angl. *Inserton*): pot → p**l**ot
- Brisanje (angl. *Deletion*): p**i**lot → plot
- Zamenjava (angl. *Substitution*): plo**d** → plo**t**

Jezikovni model (angl. *Language model*)

- Unigram, bigram, trigram
- Stupid backoff
- Ostali algoritmi za modeliranje jezika

Verjetnost urejanja

- Ustvarimo matrike zamenjav za vse štiri operacije (brisanje, vstavljanje, zamenjava, transpozicija)
- Ustvarimo matrike zamenjav za znakovne unigrame in bigrame

$$\mathit{brisanje}[a, b] = \text{število, kolikokrat se ab pojavi kot b}$$

$$\mathit{vstavljanje}[a, b] = \text{število, kolikokrat se a pojavi kot ab}$$

$$\mathit{zamenjava}[a, b] = \text{število, kolikokrat se a pojavi kot b}$$

$$\mathit{transpozicija}[a, b] = \text{število, kolikokrat se ab pojavi kot ba}$$

$$\text{š}\mathit{tevilo}[a] = \text{število, kolikokrat se pojavi znakovni unigram a}$$

$$\text{š}\mathit{tevilo}[ab] = \text{število, kolikokrat se pojavi znakovni bigram ab}$$

Kanalni model (angl. *Channel model*)

- Narobe črkovana beseda x $= x_1, x_2, x_3, ..., x_m$
- Pravilno črkovana beseda b $= b_1, b_2, b_3, ..., b_n$

Verjetnost urejanja P(x | b) izračunamo kot:

$$P(x \mid b) = \begin{cases} \frac{brisanje[b_{i-1},\ b_i]}{število[b_{i-1}\ \ b_i]} & \text{, če je brisanje} \\ \frac{vstavljanje[b_{i-1},\ x_i]}{število[b_{i-1}]} & \text{, če je vstavljanje} \\ \frac{zamenjava[x_i,\ b_i]}{število[b_i]} & \text{, če je zamenjava} \\ \frac{transpozicija[b_i,\ b_{i+1}]}{število[b_i\ \ b_{i+1}]} & \text{, če je transpozicija} \end{cases}$$

Besedne pravopisne napake

- angl. *real-word spelling errors*
- Za vsako besedo v povedi ustvarimo množico kandidatk:
  - Trenutna beseda
  - Poiščemo vse besede, ki se od trenutne razlikujejo za en znak in so besede določenega jezika
  - Enakoglasnica (angl. *homophones*) - upoštevamo izgovorjavo
- Izberemo najboljšo kandidatko:
  - Model šumnega kanala (angl. *noisy channel model*)
  - Klasifikator za specifične naloge (angl. *task-specific classifier*)

Model kanala

Nekaj faktorjev, kateri lahko vplivajo na verjetnost pravopisnih napak:

- Izvorna črka
- Ciljna črka
- Črke v okolici
- Položaj v besedi
- Tipke na tipkovnici, ki so si med seboj blizu
- Homologija na tipkovnici (razlike med tipkovnicami)
- Izgovorjava

Šumni kanal (angl. *Noisy channel*)

- Imamo poved $beseda_1, beseda_2, ..., beseda_n$
- Ustvarimo množico kandidatk za vsako besedo $beseda_n$:
  - $kandidatka(beseda_1) = \{beseda_1, beseda'_1, beseda''_1, ...\}$
  - $kandidatka(beseda_2) = \{beseda_2, beseda'_2, beseda''_2, ...\}$
  - $kandidatka(beseda_n) = \{beseda_n, beseda'_n, beseda''_n, ...\}$
- Izberemo tisto sekvenco besed B iz nabora kandidatk, ki maksimizira P(B)
- Poenostavitev (angl. *Simplification)*
  - Izmed vseh možnih povedi, kjer smo zamenjali samo eno besedo, izberemo tisto sekvenco B, ki maksimizira P(B)

Izračun verjetnosti

- Jezikovni model
  - unigram
  - bigram
  - itd.
- Kanalni model
  - Enako kot pri nebesednih pravopisnih napakah
  - Dodatno upošteva verjetnost za pravilne besede P(b | b), ki so odvisne od aplikacije
    - 0.90 (1 napaka na 10 bessed)
    - 0.95 (1 napaka na 20 besed)
    - 0.99 (1 napaka na 100 besed)
    - 0.995 (1 napaka na 200 besed)

Najsodobnejši šumni kanal

- angl. *state-of-the-art noisy channel*
- Nikoli ne množimo samo verjetnosti modela kanala in jezikovnega modela
- Predpostavka neodvisnosti $\rightarrow$ verjetnosti niso sorazmerne
- Utežimo jih:

$$\hat{b} = \underset{b \ \epsilon \ V}{\arg\max} \ P(x \mid b) \ P(b)^{\lambda}$$

- λ dobimo s pomočjo razvojne množice

Vir

- Dan Jurafsky, Chris Manning, Natural Language Processing
  `http://web.stanford.edu/~jurafsky/NLPCourseraSlides.html`

Klasifikacija besedila

(angl. Text Classification)

Ali je to nezaželena pošta?

mate presegajo meje svojega nabiralnika kvoto. Ne boste mogli pošiljati ali prejemati nova e-pošta, dokler ne boste povečali svoj nabiralnik Velikost,**Kliknite Tukaj** nadgraditi svoj račun.

Tehnična podpora

Klasifikacija elektronske pošte

Imamo 5 učnih dokumentov in 1 testni dokument.

Dokument	Zadeva	Sporočilo	Razred
d1	Must read	Get Viagra cheap	**spam**
d2	Gotta see this	Viagra you can get it at cut rates	**spam**
d3	Call me tomorrow	We need to talk about scheduling call me	**ni spam**
d4	That was hilarious	Just saw that link you sent me	**ni spam**
d5	dinner at 7	I got us a reservation tomrrow at 7	**ni spam**
d6	**See it to believe it**	**Best rates you will see**	**?**

Ali je testni dokument d6 spam ali ne?

Klasifikacija elektronske pošte

$$\mathrm{P}(\text{razred}) = \frac{N_{razred}}{N}$$
$$\mathrm{P}(\text{beseda} \mid \text{razred}) = \frac{frekvenca(beseda,razred)+1}{frekvenca(razred)+V}$$

$$P(spam) = \frac{2}{5}$$
$$P(ni\ spam) = \frac{3}{5}$$
$$\text{frekvenca}(\text{spam}) = 16$$
$$\text{frekvenca}(\text{ni spam}) = 32$$
$$\mathrm{V} = 37$$

Klasifikacija elektronske pošte

$$P(see \mid spam) = \frac{1+1}{16+37} = \frac{2}{53}$$
$$P(it \mid spam) = \frac{1+1}{16+37} = \frac{2}{53}$$
$$P(to \mid spam) = \frac{0+1}{16+37} = \frac{1}{53}$$
$$P(believe \mid spam) = \frac{0+1}{16+37} = \frac{1}{53}$$
$$P(it \mid spam) = \frac{1+1}{16+37} = \frac{2}{53}$$
$$P(best \mid spam) = \frac{0+1}{16+37} = \frac{1}{53}$$
$$P(rates \mid spam) = \frac{1+1}{16+37} = \frac{2}{53}$$
$$P(you \mid spam) = \frac{1+1}{16+37} = \frac{2}{53}$$
$$P(will \mid spam) = \frac{0+1}{16+37} = \frac{1}{53}$$
$$P(see \mid spam) = \frac{1+1}{16+37} = \frac{2}{53}$$

Klasifikacija elektronske pošte

$$P(see \mid ni\ spam) = \frac{0+1}{32+37} = \frac{1}{69}$$
$$P(it \mid ni\ spam) = \frac{0+1}{32+37} = \frac{1}{69}$$
$$P(to \mid ni\ spam) = \frac{1+1}{32+37} = \frac{2}{69}$$
$$P(believe \mid ni\ spam) = \frac{0+1}{32+37} = \frac{1}{69}$$
$$P(it \mid ni\ spam) = \frac{0+1}{32+37} = \frac{1}{69}$$
$$P(best \mid ni\ spam) = \frac{0+1}{32+37} = \frac{1}{69}$$
$$P(rates \mid ni\ spam) = \frac{0+1}{32+37} = \frac{1}{69}$$
$$P(you \mid ni\ spam) = \frac{1+1}{32+37} = \frac{2}{69}$$
$$P(will \mid ni\ spam) = \frac{0+1}{32+37} = \frac{1}{69}$$
$$P(see \mid ni\ spam) = \frac{0+1}{32+37} = \frac{1}{69}$$

Klasifikacija elektronske pošte

$$P(d6 \mid spam) = \frac{2}{5} \cdot \frac{2}{53} \cdot \frac{2}{53} \cdot \frac{1}{53} \cdot \frac{1}{53} \cdot \frac{2}{53} \cdot \frac{1}{53} \cdot \frac{2}{53} \cdot \frac{2}{53} \cdot \frac{1}{53} \cdot \frac{2}{53} = \frac{2}{5} \cdot 3.66e^{-16}$$
$$P(d6 \mid ni\ spam) = \frac{3}{5} \cdot \frac{1}{69} \cdot \frac{1}{69} \cdot \frac{2}{69} \cdot \frac{1}{69} \cdot \frac{1}{69} \cdot \frac{1}{69} \cdot \frac{1}{69} \cdot \frac{2}{69} \cdot \frac{1}{69} \cdot \frac{1}{69} = \frac{3}{5} \cdot 1.64e^{-18}$$

Dokument d6 se klasificira kot spam.

Pohitritev

Kot vidimo, so vrednosti zelo majhne.
Z uporabo logaritma se lahko izognemo računanja z vrednostmi blizu nič (angl. *Underflow*):

$$P(poved) = log(P_1 \cdot P_2 \cdot .. \cdot P_n) = logP_1 + logP_2 + .. + logP_n$$

Tudi sicer je operacija seštevanja hitrejša kot operacija množenja.

Izračun z uporabo logaritma

$$P(d6 \mid spam) = log\frac{2}{5} + log\frac{2}{53} + log\frac{2}{53} + log\frac{1}{53} +$$
$$log\frac{1}{53} + log\frac{2}{53} + log\frac{1}{53} + log\frac{2}{53} + log\frac{2}{53} + log\frac{1}{53} + log\frac{2}{53} = log\frac{2}{5} - 15.4$$
$$P(d6 \mid ni\ spam) = log\frac{3}{5} + log\frac{1}{69} + log\frac{1}{69} + log\frac{2}{69} +$$
$$log\frac{1}{69} + log\frac{1}{69} + log\frac{1}{69} + log\frac{1}{69} + log\frac{2}{69} + log\frac{1}{69} + log\frac{1}{69} = log\frac{3}{5} - 17.8$$

Katerem naravnem jeziku pripada besedilo?

- Osnovna naloga procesiranja besedil.
- Omogoča obdelavo velike količine digitalnih dokumentov.
- Na osnovi klasifikacije se zmanjša napaka oz. izboljša učinkovitost algoritmov procesiranja besedila.
  (npr.: črkovalnik, ugotavljanje slovničnih napak, razpoznavanje besedila itd.)

Katerem naravnem jeziku pripada besedilo?

- Predstavljena bo metoda, ki temelji na znakovnih n-gramih.
- Lastnosti: hitrost in robustnost.
- Točnost metode je večja od 80%. V določenih primerih tudi večja od 99%.
- Temelji na ugotavljanju frekvenc n-gramov.

Katerem naravnem jeziku pripada besedilo?

Lastnosti klasifikatorja besedil

- Neobčutljiv na napake v besedilu.
- Učinkovitost (prostorska in časovna)
- Zmožen ugotoviti, da dokument ne pripada nobenemu razredu.
- Zmožen ugotoviti, da je dokument na meji med dvema razredoma.

Znakovni n-grami

- Del besedila, ki je sestavljen iz N-znakov.
- Vsebujejo nevidne znake.
  - Na začetku in koncu besede.
  - Ločevanje besed.
- Primer za: _besedilo_
  - bigrami: _b,be, es, se, ed, di, il, lo, o_
  - trigrami: _be, bes, ese, sed, edi, dil, ilo, lo_
  - štirigrami: _bes, bese, esed, sedi, edil, dilo, ilo_

Klasifikacija - frekvenca znakovnih n-gramov

- Za razlago ideje uporabimo Zipfov zakon
  - V vsakem naravnem jeziku je pogostost n-te najpogosteje uporabljane besede približno recipročno odvisna od n.
- V vsakem jeziku dominirajo frekvence določenih besed.
- Podobno lahko povzamemo za n-grame v besedilu.
- Besedila, ki sodijo v določen razred bodo imela verjetno podobno frekvenco besed.

Algoritem klasifikacije besedila

- Besedilo razdelimo na leksikalne simbole. Pri tem odstranimo posebne znake in števila. Vsakemu leksikalnemu simbolu dodamo na začetku in koncu presledek.
- Za vsak leksikalni simbol ustvarimo n-grame ($N \in \{1, \ldots, 5\}$).
- V sekljani tabeli shranjujte n-grame in štejte njihove pojavitve. Sekljana tabela vsebuje klasičen mehanizem, ki zagotavlja, da so v primeru kolizij vsi n-grami shranjeni.
- N-grame uredite po njihovih števcih-frekvencah padajoče in jih shranite skupaj v profil. Ponavadi shranimo 300 najbolj frekvenčnih n-gramov.

Algoritem klasifikacije besedila

- 300 najbolj frekvenčnih n-gramov ponavadi dovolj opisuje določen jezik.
- Najbolj frekvenčni n-grami so uni-grami in predstavljajo korelacijo med črkami. Nato sledijo pogoste predpone (angl. *prefix*) in pripone (angl. *sufix*) besed.
- Dolgi in frekvenčni n-grami se uvrstijo na rep seznama 300 najbolj frekvenčnih n-gramov.
- N-grami v okolici 300. mesta najbolj frekvenčnih n-gramov predstavljajo n-grame, ki so specifični za področje dokumenta.

Primerjava profilov dokumentov

- Izračun vsote razdalj med rangi n-gramov.
- V primeru neujemanja n-gramov se uporabi neka velika vrednost (300).
- Dokument dodelimo v razred, kjer je razlika profilov najmanjša.

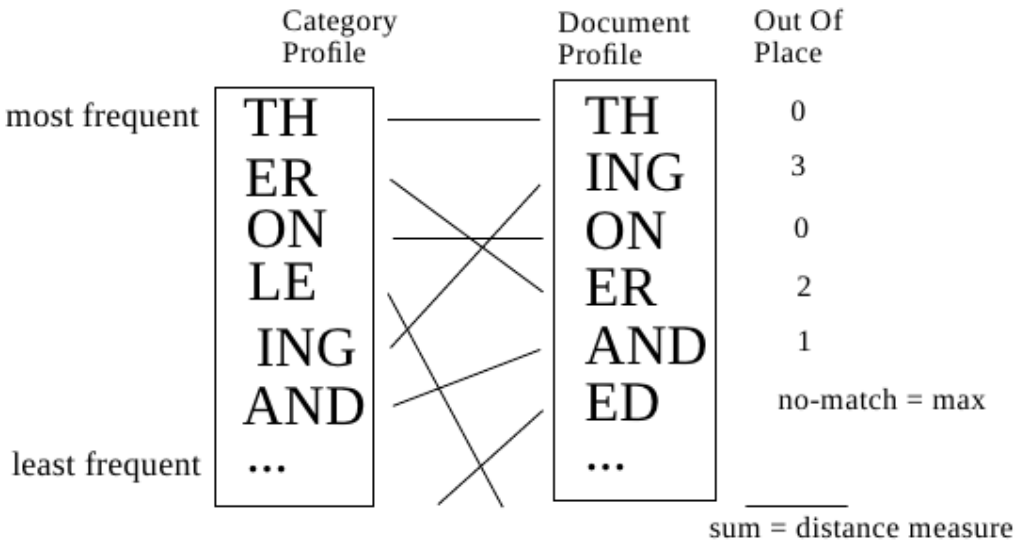

William B. Cavnar in John M. Trenkle, N-Gram-Based Text Categorization

Ugotovite spol avtorja besedila

- Al-Eksandra je intimna pripoved ženske, ki je kot devetnajstletno dekle zagledalo plakat eksotične dežele, spakiralo mali kovček in odšlo. Brez pomislekov je zapustila Slovenijo, vse, kar ji je bilo znano, in se prepustila toku življenja v tujini in neznani deželi. Deželi, polni nasprotij, deželi, kjer je desetletja potekala vojna - vse to je Libanon.
- Genom mojega življenja je avtobiografska pripoved dr. J. Craiga Venterja, kalifornijskega jadralca, ki ga je služba bolničarja v Vietnamu tako prekalila, da se je s trmasto vztrajnostjo prelevil v pionirja genomike. V knjigi je najnovejša dognanja genetike uporabil kar na samem sebi, ko je avtobiografsko pripoved prepletel s kratkimi razlagami delov svojega genoma, ki ga je leta 2007 tudi objavil.

Pozitivna ali negativna ocena filma

- ✘ Torej ... nekako nisem dojel filma, tako da je moja ocena žal negativna.
- ✔ Film lahko ocenim zelo pozitivno, saj je zgodba ves čas v dogajanju in napetosti.
- ✘ Kljub komercialnemu uspehu je film Melanie se poroči s strani kritikov prejel v glavnem negativne ocene.
- ✘ Na žalost je ta film popoln polom.
- ✘ Vsaj kar se mene tiče, pa tudi ocene kritikov niso najbolj pozitivne.
- ✔ Krasen film, vreden ogleda.
- ✔ Od filma sem pričakovala manj, verjetno me je zato tako pozitivno presenetil.

Področje članka

Članek

Evolution: A Comparative Study on Numerical Benchmark Problems

Janez Brest, *Member, IEEE*, Sašo Greiner, Borko Bošković, Marjan Mernik, *Member, IEEE*, and Viljem Žumer, *Member, IEEE*

***Abstract*—We describe an efficient technique for adapting control parameter settings associated with differential evolution (DE). The DE algorithm has been used in many practical cases and has demonstrated good convergence properties. It has only a few control parameters, which are kept fixed throughout the entire evolutionary process. However, it is not an easy task to properly set control parameters in DE. We present an algorithm—a new version of the DE algorithm—for obtaining self-adaptive control parameter settings that show good performance on numerical benchmark problems. The results show that our algorithm with self-adaptive control parameter settings is better than, or at least comparable to, the standard DE algorithm and evolutionary algorithms from literature when considering the quality of the solutions obtained.**

***Index Terms*—Adaptive parameter control, differential evolution (DE), evolutionary optimization.**

I. Introduction

DIFFERENTIAL evolution (DE) is a simple yet powerful evolutionary algorithm (EA) for global optimization introduced by Price and Storn [1]. The DE algorithm has gradually become more popular and has been used in many practical cases, mainly because it has demonstrated good convergence properties and is principally easy to understand [2].

EAs [3] are a broad class of stochastic optimization algorithms inspired by biology and, in particular, by those biological processes that allow populations of organizms to adapt to their surrounding environments: genetic inheritance and survival of the fittest. EAs have a prominent advantage over other types of numerical methods. They only require information about the objective function itself, which can be either explicit or implicit. Other accessory properties such as differentiability or continuity are not necessary. As such, they are more flexible in dealing with a wide spectrum of problems.

When using an EA, it is also necessary to specify how candidate solutions will be changed to generate new solutions [4]. EA may have parameters, for instance, the probability of mutation, the tournament size of selection, or the population size. The values of these parameters greatly determine the quality of the solution obtained and the efficiency of the search [5]–[7]. Starting with a number of guessed solutions, the multipoint algorithm updates one or more solutions in a synergistic manner in the hope of steering the population toward the optimum [8], [9].

Choosing suitable parameter values is, frequently, a problem-dependent task and requires previous experience of the user. Despite its crucial importance, there is no consistent methodology for determining the control parameters of an EA, which are, most of the time, arbitrarily set within some predefined ranges [4].

In their early stage, EAs did not usually include control parameters as a part of the evolving object but considered them as external fixed parameters. Later, it was realized that in order to achieve optimal convergence, these parameters should be altered in the evolution process itself [5], [7].

The control parameters were adjusted over time by using heuristic rules, which take into account information about the progress achieved. However, heuristic rules, which might be optimal for one optimization problem, might be inefficient or even fail to guarantee convergence for another problem. A logical step in the development of EAs was to include control parameters into the evolving objects and allow them to evolve along with the main parameters [3], [10], [11].

Globally, we distinguish two major forms of setting parameter values: parameter *tuning* and parameter *control*. The former means the commonly practiced approach that tries to find good values for the parameters before running the algorithm, then tuning the algorithm using these values, which remain fixed during the run. The latter means that values for the parameters are changed during the run. According to Eiben *et al.* [5], [7], the change can be categorized into three classes.

1) *Deterministic parameter control* takes place when the value of a parameter is altered by some deterministic rule.
2) *Adaptive parameter control* is used to place when there is some form of feedback from the search that is used to determine the direction and/or the magnitude of the change to the parameter.
3) *Self-adaptive parameter control* is the idea that "evolution of the evolution" can be used to implement the self-adaptation of parameters. Here, the parameters to be adapted are encoded into the chromosome (individuals) and undergo the actions of genetic operators. The better values of these encoded parameters lead to better individuals which, in turn, are more likely to survive and produce offspring and, hence, propagate these better parameter values.

Manuscript received June 14, 2005; revised September 19, 2005 and November 9, 2005. This work was supported in part by the Slovenian Research Agency under Programme P2-0041, Computer Systems, Methodologies, and Intelligent Services.

The authors are with the Computer Architecture and Languages Laboratory, Institute of Computer Science, Faculty of Electrical Engineering and Computer Science, University of Maribor, SI-2000 Maribor, Slovenia (e-mail: janez.brest@uni-mb.si; saso.greiner@uni-mb.si; borko.boskovic@uni-mb.si; marjan.mernik@uni-mb.si; zumer@uni-mb.si).

Digital Object Identifier 10.1109/TEVC.2006.872133

⟹

Področje

- Diferencialna evolucija
- Genetski algoritmi
- Roji delcev
- Mravlje
- Čebelice

Klasifikacija besedila

- Določanje vsebine, kategorije, teme ali žanra
- Odkrivanje nezaželene pošte
- Identificiranje avtorjev
- Ugotavljanje starosti/spola
- Identificiranje jezika (angl. *Language Identification*)
- Analiza sentimenta - odkrivanje mnenja, ki ga podaja neko besedilo (angl. *Sentiment analysis*)
- ...

Definicija klasifikacije besedila

- **Vhod**:
  - Dokument d
  - Fiksna množica razredov $C = \{c_1, c_2, ..., c_n\}$
- **Izhod**:
  - Izbran razred $c \in C$ v katerega sodi podan dokument d

Klasifikacijske metode - ročno določena pravila

- Pravila, ki določajo kombinacijo zaporedja besed ali drugih lastnosti
  - Nezaželena pošta: naslov iz črnega seznama ali sporočilo vsebuje naslednji zaporedji besed: “nagrada” in “bili ste izbrani”
- Točnost lahko povečamo
  - Izpopolnimo pravila s pomočjo strokovnjakov
- Gradnja in vzdrževanje teh pravil je drago opravilo

Klasifikacijske metode - nadzorovano strojno učenje

- **Vhod**:
  - Dokument d
  - Fiksna množica razredov $C = c_1, c_2, ..., c_n$
  - Učna množica, ki vsebuje m ročno klasificiranih dokumentov $(d_1, c_1), (d_2, c_2), ..., (d_m, c_m)$
- **Izhod**:
  - Naučen klasifikator $\gamma : d \rightarrow c$
- Klasifikatorji:
  - Naïve Bayes
  - Logistična regresija
  - Support–vector machines
  - K-najbližjih sosedov

Naïve Bayes

- Enostavni ("Naïve") klasifikator, ki temelji na pravilih Bayes
- Temelji na zelo preprosti predstavitvi dokumenta
  - Vreča besed

Vreča besed

Vreča

Sem ga ravnokar pogledal in ga toplo priporočam vsakomur. Misterioznost, napeta zgodba, odlična stripovska podlaga. Ta film bo najbrž eden boljših letos. Še ena izmed meni osebno najljubših tem - alternativna zgodovina oz. anti-utopična družbena ureditev. Zgodba je odlična, čeprav nekoliko ozka, na ogromno vprašanj si mora gledalec odgovoriti sam.

$$\gamma(\quad) = C$$

Vreča besed

Vreča

Sem ga ravnokar pogledal in ga **toplo priporočam** vsakomur. Misterioznost, napeta zgodba, **odlična** stripovska podlaga. Ta film bo najbrž eden **boljših** letos. Še ena izmed meni osebno najljubših tem - alternativna zgodovina oz. anti-utopična družbena ureditev. Zgodba je **odlična**, čeprav nekoliko ozka, na ogromno vprašanj si mora gledalec odgovoriti sam.

$$\gamma(\quad) = C$$

Vreča besed

$$\gamma(\quad) = C$$

Vreča

Xxx xx xxxxxxxx xxxxxxxx xx xx **toplo priporočam** xxxxxxxx. Xxxxxxxxxxxxx, xxxxxx xxxxxx, **odlična** xxxxxxxxxx xxxxxxx. Xx xxxx xx xxxxxx xxxx **boljših** xxxxx. Xx xxx xxxxx xxxx xxxxxx **najljubših** xxx - xxxxxxxxxxxx xxxxxxxxx xx. xxxx-xxxxxxxx xxxxxxxx xxxxxxxx. Xxxxxx xx **odlična**, xxxxxx xxxxxxxx xxxx, xx xxxxxxx xxxxxxxx xx xxxx xxxxxxxx xxxxxxxxxx xxx.

Vreča besed

Vreča

$$\gamma\left(\begin{array}{|c|c|}\hline \text{odlična} & 2 \\ \text{toplo} & 1 \\ \text{priporočam} & 1 \\ \text{boljših} & 1 \\ \text{najljubših} & 1 \\ \hline\end{array}\right) = C$$

Pravila Bayes - dokumenti in razredi

- Za dokument d in razred c

$$P(c|d) = \frac{P(d|c)P(c)}{P(d)}$$

Klasifikator Naïve Bayes

$$c_{MAP} = \arg\max_{c \in C} P(c|d)$$

Pravila Bayes

$$= \arg\max_{c \in C} \frac{P(d|c)P(c)}{P(d)}$$

P(d) je za vse razrede enak in ga lahko odstranimo

$$= \arg\max_{c \in C} P(d|c)P(c)$$

Uporabimo lastnosti dokumenta

$$= \arg\max_{c \in C} P(x_1, x_2, ..., x_n|c)P(c)$$

MAP je "maximum a posteriori" = najbolj verjetni razred

Multinominalni Naïve Bayes

Predpostavke neodvisnosti

$$P(x_1, x_2, ..., x_n|c)$$

- Predpostavka vreče besed: položaj besed ni pomemben
- Pogojna neodvisnost: za določen razred c so verjetnosti posameznih lastnosti $P(x_i|c_j)$ neodvisne

$$P(x_1, x_2, ..., x_n|c) = P(x_1|c) \cdot P(x_2|c) \cdot ... \cdot P(x_n|c)$$

Multinominalni Naïve Bayes

$$c_{MAP} = \arg\max_{c \in C} \; P(x_1, x_2, ..., x_n|c)P(c)$$

$$c_{NB} = \arg\max_{c \in C} \; P(c) \prod_{x \in X} P(x|c)$$

Multinominalni Naïve Bayes

Klasifikacija besedila

$$c_{NB} = \arg\max_{c_j \in C} P(c_j) \prod_{i \in \text{položaj}} P(x_i|c_j)$$

Položaj vsebuje vse položaje besed v besedilu

Učenje modela Multinominal Naïve Bayes

- Ocenjevanje maksimalne verjetnosti
  - Preprosto uporabimo frekvence podatkov

$$\hat{P}(c_j) = \frac{\text{številoDokumentov}(C = c_j)}{\text{številoDokumentov}}$$

$$\hat{P}(b_i|c_j) = \frac{\text{število}(b_i, c_j)}{\sum_{b \in V} \text{število}(b, c_j)}$$

  - Vse dokumente, ki pripadajo določenemu razredu združimo v "mega" dokument
    - Na osnovi "mega" dokumenta se računajo frekvence besed

Metode maksimalnega verjetja - problem

- Problemi z ne videnimi besedami

$$\hat{P}(\text{“fantastično”}|\text{pozitivno}) = \frac{\text{število}(\text{“fantastično”},\text{pozitivno})}{\sum_{b \in V} \text{število}(b, \textit{pozitivno})} = 0$$

$$c_{MAP} = \arg\max_{c} \hat{P}(c) \prod_{i} \hat{P}(x_i|c)$$

Glajenje Laplace (add-1) za Naïve Bayes

$$\hat{P}(b_i|c) = \frac{\text{število}(b_i, c) + 1}{\sum_{b \in V}(\text{število}(b, c) + 1)}$$

$$= \frac{\text{število}(b_i, c) + 1}{(\sum_{b \in V} \text{število}(b, c)) + |V|}$$

Multinominal Naïve Bayes - učenje

- Iz učnega korpusa se izlušči slovar (angl. *Vocabulary*)
- Izračunajo se $P(c_j)$
  - $dok_j \leftarrow$ vsi dokumenti razredac_j
  - $P(c_j) = \frac{|dok_j|}{|\text{število vseh dokumentov}|}$
- Izračunajo se $P(b_k|c_j)$
  - $besedilo_j \leftarrow$ dokument, ki vsebuje vse dokumente dok_j
  - Za vsako besedo b_k iz slovarja
    - $n_k \leftarrow$ število pojavitev besede b_k v $besedilo_j$
    - $P(b_k|c_j) \leftarrow \frac{n_k+\alpha}{n+\alpha|slovar|}$
    - n - število leksikalnih simbolov v razredu c_j

Glajenje Laplace (add-1): neznane besede

- V slovar dodamo neznano besedo $b_{neznana}$

$$\hat{P}(b_{neznana}|c) = \frac{\text{število}(b_{neznana}, c) + 1}{(\sum_{b \in V} \text{število}(b, c)) + |V + 1|}$$

$$= \frac{1}{(\sum_{b \in V} \text{število}(b, c)) + |V + 1|}$$

Naïve Bayes in jezikovni modeli

- Naïve Bayes lahko uporablja različne značilke.
  - URL, E-pošta, slovarji, značilke omrežja itd.
- V našem primeru besede predstavljajo značilke.
- Podobnost klasifikatorja Naïve Bayes z jezikovnimi modeli
  - Vsak razred lahko enačimo z jezikovnim modelom (unigram).
  - Vsaki besedi dodelimo verjetnost $P(beseda|c)$.
  - Vsakemu stavku dodelimo verjetnost $P(stavek|c) = \prod P(beseda|c)$.

Lastnosti metode Naïve Bayes

- Mala časovna zahtevnost
- Mala prostorska zahtevnost
- Robusten na nepomembne lastnosti
  - Nepomembne lastnosti ne vplivajo na končni rezultat
- Je dobra metoda za klasifikacijo beselida
  - Obstajajo boljše metode

Kako oceniti uspešnost klasifikacije besedila

podatki / klasifikacija	nezaželena pošta	ni nezaželena pošta
nezaželena pošta	resnični pozitivni (tp)	lažno pozitivni (fp)
ni nezaželena pošta	lažno negativni (fn)	resnični negativni (tn)

- Točnost (angl. *Accuracy*): $\frac{tp+tn}{tp+tn+fp+fn}$

Kako oceniti uspešnost klasifikacije besedila

	znamke avtomobilov	ostalo
znamke avtomobilov	0 (tp)	0 (fp)
ostalo	10 (fn)	99.990 (tn)

- Točnost (angl. *Accuracy*):$Acc = \frac{tp+tn}{tp+tn+fp+fn} = \frac{99.990}{100.000} = 99,99\%$
- Vrednost ne izraža kvalitete klasifikatorja
- Preciznost (angl. *Precision*): razmerje med številom vseh pozitivnih primerov $\frac{tp}{tp+fp} = 0\%$
- Priklic (angl. *Recall*): razmerje med vsemi pozitivnimi primeri, ki smo jih pravilno napovedali in številom vseh primerov, za katere smo napovedali, da pripadajo pozitivnemu razredu $\frac{tp}{tp+fn} = 0\%$

Kako oceniti uspešnost klasifikacije besedila

	znamke avtomobilov	ostalo
znamke avtomobilov	8 (tp)	32 (fp)
ostalo	2 (fn)	99.960 (tn)

- Točnost (angl. *Accuracy*):$Acc = \frac{tp+tn}{tp+tn+fp+fn} = \frac{99.968}{100.002} = 99,99\%$
- Vrednost ne izraža kvalitete klasifikatorja
- Preciznost (angl. *Precision*): razmerje med številom vseh pozitivnih primerov $P = \frac{tp}{tp+fp} = \frac{8}{8+32} = 20\%$
- Priklic (angl. *Recall*): razmerje med vsemi pozitivnimi primeri, ki smo jih pravilno napovedali in številom vseh primerov, za katere smo napovedali, da pripadajo pozitivnemu razredu $R = \frac{tp}{tp+fn} = \frac{8}{10} = 80\%$
- Potrebujemo kompromis med preciznostjo in priklicem.

Mera F

- Kompromis med preciznostjo in priklicem (harmonično uteženo povprečje).
  - $F = \frac{1}{\alpha \frac{1}{P} + (1-\alpha)\frac{1}{R}} = \frac{(\beta^2+1)PR}{\beta^2 P + R}$
- Ponavadi se uporablja uglašena mera F1:
  - npr. $\beta = 1$ oz. $\alpha = \frac{1}{2}$; $F = \frac{2PR}{P+R}$

Mikro in makro povprečenje

- angl. *Micro vs. Macro Averaging*
- Če imamo več kot eden razred, kako oceniti uspešnost klasifikatorja z eno vrednostjo?
- Makro povprečenje: izračunamo uspešnost za vsak razred posebej in nato izračunamo povprečje uspešnosti.
- Mikro povprečenje: Združimo dobljene rezultate klasifikatorja in na osnovi teh podatkov izračunamo uspešnost.

Mikro in makro povprečenje

	razred 1	ostalo
razred 1	10 (tp)	10 (fp)
ostalo	10 (fn)	970 (tn)

	razred 2	ostalo
razred 2	90 (tp)	10 (fp)
ostalo	10 (fn)	890 (tn)

	razed sum	ostalo
razred sum	100 (tp)	20 (fp)
ostalo	20 (fn)	1860 (tn)

- Makro povprečenje preciznosti: $\frac{\frac{10}{20}+\frac{90}{100}}{2} = 0,7$
- Mikro povprečenje preciznosti: $\frac{100}{120} = 0,83$
- Pri mikro povprečenju prevladujejo rezultati splošnih razredov.

Razvojna množica in navzkrižna validacija

- Metrike: P/R/F1
- Učna množica
- Ne videna testna množica
- Navzkrižna validacija skozi večkratno razdelitev učne množice in razvojne množice

Izgradnja realnega klasifikatorja

- Ni podatkov
  - Ročno
  - Velika časovna zahtevnost
- Na voljo zelo malo podatkov
  - Metoda Naïve Bayes
- Ustrezna količina podatkov
  - SVM (angl. *Support Vector Machines*)
  - Odločitvena drevesa
  - Urejena logistična regresija (angl. *Regularized Logistic Regression*)
- Enormna količina podatkov
  - Metoda Naïve Bayes

Premajhna števila

- Z množenjem verjetnosti, lahko dobimo zelo mala števila.
- $log(x \cdot y) = log(x) + log(y)$
- Klasifikator:
  $C_{NB} = \arg\max log\ P(C_j) + \sum_{i \in pozicija} log\ P(x_i|c_j)$

Kako izboljšati učinkovitost klasifikatorja

- Domensko specifične značilke in uteži
- Dodatno obtežiti določene besede
  - Besede v naslovu
  - Prvi stavek vsakega odstavka
  - Stavke, ki vsebujejo besede iz naslova
- Določene izraze zanemarimo
  - števila, enačbe, itd.

Viri

- Dan Jurafsky, Chris Manning, Natural Language Processing http://web.stanford.edu/∼jurafsky/NLPCourseraSlides.html
- Monika Bozhinova, NAIVNI BAYESOV KLASIFIKATOR, Diplomsko delo, 2015.
- William B. Cavnar in John M. Trenkle, N-Gram-Based Text Categorization

Primeri nalog

Poglavja

- Pregled jezikovnih tehnologij
- Osnovno procesiranje besedila
- Razdalja urejanja
- Modeliranje jezika
- Popravljanje pravopisa
- Klasifikacija

Primeri nalog

- 1. Napišite sekvenco ukazov v lupini bash za izračun frekvenc besed, ki vsebujejo šumnike. Izpis frekvenc naj bo padajoč. Pri tem upoštevajte, da so pri kodiranju UTF-8 šumniki predstavljeni z dvema znakoma.
- cat jrc-acquis.sl | sed s/[^A-Za-zČŠŽčšž]/\\n/g | grep [ČŠŽčšž] | sort | uniq -c | sort -rn > sequence.txt
- Rezultati
  - 114366 št
  - 110294 Člen
  - 91391 člena
  - 71652 članice
  - 68468 države
  - 67203 upoštevanju
  - 43287 če
  - 42985 držav
  - 38527 pomoči
  - 32886 členom
  - 28635 členu

Primeri nalog

- Pokažite način delovanja algoritma za minimalno razdaljo urejanja in poravnavo besed banana in salama.

	/	s	a	l	a	m	a
/	0	1	2	3	4	5	6
b	1	2 z	3	4	5	6	7
a	2	3	2 -	3	4	5	6
n	3	4	3	4 z	5	6	7
a	4	5	4	5	4 -	5	6
n	5	6	5	6	5	6 z	7
a	6	7	6	7	6	7	6 -

Naloga

- Imamo dva jezikovna modela M1 in M2. Za oba modela izračunajte perpleksnost in povejte kateri model je boljši.
- Poved: <s> Strupen jezik je nevarnejši od strupene kače </s>
- M1:
  P(Strupen| <s>)=$\frac{1}{13}$, P(jezik|Strupen)=$\frac{1}{14}$, P(je|jezik)=$\frac{1}{15}$,
  P(nevarnejši|je)=$\frac{2}{29}$, P(od|nevarnejši)=$\frac{2}{25}$, P(strupene|od)=$\frac{1}{79}$;
  P(kače|strupene)=$\frac{4}{41}$, P(</s> |kače)=$\frac{1}{128}$
- M2:
  P(Strupen| <s>)=$\frac{7}{10}$;P(jezik|Strupen)=$\frac{2}{10}$;P(je|jezik)=$\frac{1}{55}$;
  P(nevarnejši|je)=$\frac{3}{35}$, P(od|nevarnejši)=$\frac{4}{25}$;P(strupene|od)=$\frac{5}{44}$;
  P(kače|strupene)=$\frac{3}{13}$;P(</s> |kače)=$\frac{1}{99}$
- $PP(S_{M1}) = (\frac{1}{13} \cdot \frac{1}{14} \cdot \frac{1}{15} \cdot \frac{2}{29} \cdot \frac{2}{25} \cdot \frac{1}{79} \cdot \frac{4}{41} \cdot \frac{1}{128})^{-\frac{1}{8}} = 21,81475$
- $PP(S_{M2}) = (\frac{7}{10} \cdot \frac{2}{10} \cdot \frac{1}{55} \cdot \frac{3}{35} \cdot \frac{4}{25} \cdot \frac{5}{44} \cdot \frac{3}{13} \cdot \frac{1}{99})^{-\frac{1}{8}} = 10,09834$
- Manjša perpleksnost nakazuje boljši model.

Naloga

- <s>med igralci maribora ni bilo branilcev, pri olimpiji pa nosilcev</s>
  <s>trener olimpije je moral poseči po mladih močeh</s>
  <s>tekmo so z nekaj obetavnimi akcijami začeli igralci olimpije</s>
  <s>igralci maribora so resneje zapretili v 13 minuti</s>
  <s>mariborčani bi lahko povedli tudi v 22 minuti</s>
  <s>v 30 minuti je skomina pokazal na belo točko</s>
  <s>do vodstva maribora ni prišlo</s>
- Z uporabo modela bigram in glajenjem Add-1 izračunajte, kateri stavek ima večjo verjetnost, da bo izbran:
  - S_1 :<s>igralci maribora bodo prvaki</s>
  - S_2 :<s>igralci olimpije bodo prvaki</s>
- Velikost slovarja: 47

Naloga

- $P(\text{igralci}|<s>)=\frac{1+1}{7+47}$
- $P(\text{maribora}|\text{igralci})=\frac{2+1}{3+47}$
- $P(\text{bodo}|\text{maribora})=\frac{0+1}{3+47}$
- $P(\text{prvaki}|\text{bodo})=\frac{0+1}{0+47}$
- $P(</s>|\text{prvaki})=\frac{0+1}{0+47}$
- $P(S_1) = \frac{1+1}{7+47} \cdot \frac{2+1}{3+47} \cdot \frac{0+1}{3+47} \cdot \frac{0+1}{0+47} \cdot \frac{0+1}{0+47} = 2,011971e-08$
- $P(\text{igralci}|<s>)=\frac{1+1}{7+47}$
- $P(\text{olimpije}|\text{igralci})=\frac{1+1}{2+47}$
- $P(\text{bodo}|\text{olimpije})=\frac{0+1}{2+47}$
- $P(\text{prvaki}|\text{bodo})=\frac{0+1}{0+47}$
- $P(</s>|\text{bodo})=\frac{0+1}{0+47}$
- $P(S_2) = \frac{1+1}{7+47} \cdot \frac{1+1}{2+47} \cdot \frac{0+1}{2+47} \cdot \frac{0+1}{0+47} \cdot \frac{0+1}{0+47} = 1,3966203171e-08$

Naloga

- Podan imate naslednji korpus:
  - <s>jaz sem ivan</s>
  - <s>moje ime je ivan</s>
  - <s>sem ivan</s>
  - <s>torej moje ime je ivan</s>
- S pomočjo interpoliranega glajenja Kneser-Ney izračunajte $P_{KN}(ivan|je)$. Pri tem upoštevajte, da je
  - $d = 1$
  - število$(je, ivan) = 2$
  - število$(je) = 2$
  - število$(ivan) = 4$
  - $|\{b : \text{število}(je, b) > 0\}| = 1$
  - $|\{(b_{j-1}, b_j) : \text{število}(b_{j-1}, b_j) > 0\}| = 11$
  - $|\{b_{i-1} : \text{število}(b_{i-1}, ivan) > 0\}| = 2$

Naloga

$$P_{KN}(b_i|b_{i-1}) = \frac{max(število(b_{i-1}, b_i) - d, 0)}{število(b_{i-1})} + \lambda(b_{i-1}) P_{nadaljevanja}(b_i)$$

$\lambda(b_{i-1})$ je normalizirana konstanta:

$$\lambda(b_{i-1}) = \frac{d}{število(b_{i-1})} |\{b : število(b_{i-1}, b) > 0)\}|$$

$$P_{nadaljevanja}(b) = \frac{|\{b_{i-1} : število(b_{i-1}, b) > 0\}|}{|\{(b_{j-1}, b_j) : število(b_{j-1}, b_j) > 0\}|}$$

$$P_{KN}(ivan|je) = \frac{max(2-1, 0)}{2} + \frac{1}{2} \cdot 1 \cdot \frac{2}{11} = \frac{1}{2} + \frac{2}{22}$$

Naloga

- S pomočjo rekurzivne enačbe Kneser-Ney izračunajte $P_{KN}(\check{s}tudent|je\ ivan)$.

$$P_{KN}(b_i|b_{i-n+1}^{i-1}) = \frac{max(\check{s}t_{KN}(b_{i-n+1}^{i}) - d, 0)}{\check{s}t_{KN}(b_{i-n+1}^{i-1})} + \lambda(b_{i-n+1}^{i-1}) P_{KN}(b_i|b_{i-n+2}^{i-1})$$

$$\check{s}t_{KN}(\bullet) = \begin{cases} \check{s}tevilo(\bullet) & za\ višje\ stopnje\ n\text{-}gramov \\ \check{s}tevilo_{nadaljevanja}(\bullet) & za\ n\text{-}grame\ 1.\ stopnje \end{cases}$$

Kako se izognemo ničelnim vrednostim:

- **V fazi učenja vse n-grame, ki se ponovijo zelo malo krat, obravnavamo kot neznane n-grame. Informacijo o neznanih n-gramih nato uporabimo za izračun verjetnosti neznanih n-gramov.**
- $P_{KN}(\mathrm{b}) = P_{nadaljevanja}(\mathrm{b}) + \lambda(\varepsilon)P(\varepsilon)$
  $P(\varepsilon) = \frac{1}{|V|}; \quad \lambda(\varepsilon) = d$

Naloga

$$P_{KN}(\text{študent}|\textit{je ivan}) = \frac{max(\text{število}(\text{je ivan študent}) - d, 0)}{\text{število}(\text{je ivan})} + \lambda(\text{je ivan}) *$$

$$\left(\frac{max(\text{število}(\text{ivan študent}), 0)}{\text{število}(\text{ivan})} + \lambda(\textit{ivan}) * \right.$$

$$\left. \left(P_{nadaljevanja}(\text{študent}) + \lambda(\varepsilon) P(\varepsilon) \right) \right) =$$

$$\frac{max(\text{število}(\text{je ivan študent}) - d, 0)}{\text{število}(\text{je ivan})} + \frac{d * |\{b : \text{število}(\textit{je}, \textit{ivan}, b) > 0\}|}{\text{število}(\text{je ivan})} *$$

$$\left(\frac{max(\text{število}(\text{ivan študent}) - d, 0)}{\text{število}(\text{ivan})} + \frac{d * |\{b : \text{število}(\textit{ivan}, b) > 0\}|}{\text{število}(\textit{ivan})} * \right.$$

$$\left. \left(\frac{|\{b_{i-1} : \textit{število}(b_{i-1}, \text{študent} > 0\}|}{|\{(b_{j-1}, b_j) : \textit{število}(b_{j-1}, b_j) > 0\}|} + d * \frac{1}{|V|} \right) \right) =$$

Naloga

$$P_{KN}(\text{študent}|\textit{je ivan}) = \frac{max(0-1,0)}{2} + \frac{1*1}{2} * \left(\frac{max(0-1,0)}{4} + \frac{1*1}{4} * \left(\frac{0}{11} + 1 * \frac{1}{7} \right) \right) = 0 + \frac{1}{2} * \left(0 + \frac{1}{4} * \left(0 + \frac{1}{7} \right) \right) = \frac{1}{2} * \frac{1}{4} * \frac{1}{7} = \frac{1}{56}$$

Naloga

- Izračunajte verjetnost podanega stavka še s pomočjo metode "Stupid backoff“ (bigram in trigram)
- Izračunajte verjetnost podanega stavka še s pomočjo metode "Good-Turing“ (bigram)

Naloga

$$S(b_i|b_{i-k+1}^{i-1}) = \begin{cases} \frac{\text{število}(b_{i-k+1}^{i})}{\text{število}(b_{i-k+1}^{i-1})} & \text{če število}(b_{i-k+1}^{i}) > 0 \\ 0{,}4S(b_i|b_{i-k+2}^{i-1}) & \text{drugače} \end{cases}$$

$$S(b_i) = \frac{\text{število}(b_i)}{N}$$

Naloga

Primer za bigram P(ivan|je):

$$S(\text{ivan}|\text{je}) = \frac{\text{število(je, ivan)}}{\text{število(je)}} = \frac{2}{2} = 1$$

Primer za trigram P(ivan|kriv je):

$$S(\text{ivan}|\text{kriv je}) = \frac{\text{število(kriv, je, ivan)}}{\text{število(kriv, je)}}$$

število(kriv, je, ivan) = 0 (ni večje od 0, zato uporabimo informacije o bigramih)

$$S(\text{ivan}|\text{kriv je}) = 0,4 \cdot S(\textit{ivan}|\textit{je}) = 0,4 \cdot \frac{\text{število(je, ivan)}}{\text{število(je)}} = 0,4$$

Naloga

- $P^*_{GT}(\text{stvari z ničelno frekvenco}) = \frac{N_1}{N}$
- $c^* = \frac{(c+1)N_{c+1}}{N_c}(\text{Stvari z ne ničelno frekvenco})$

$$
\begin{aligned}
c &= 2 \\
N_3 &= 0, \text{ po prilagoditveni funkciji dobimo} N_3 = 2 \\
c^* &= \frac{(c+1)N_{c+1}}{N_c} = \frac{3 \cdot 2}{4} = \frac{6}{4} = \frac{3}{2} \\
N &= 14 \\
P^*_{GT}(ivan|je) &= \frac{c^*}{N} = \frac{\frac{3}{2}}{14} = \frac{3}{28}
\end{aligned}
$$

Naloga

- Recimo, da želimo zgladiti verjetnosti model šumnega kanala za črkovanje:
- Imejmo dve besedi, x in y, kjer se x od y razlikuje v dveh črkah.
- Črka x_i v besedi x je zamenjana s črko y_i v besedi y.
- Želimo aplicirati glajenje add-1 na $P(x|y)$ oz. verjetnost, da sta zamenjani črki x_i in y_i.
- Metoda največjega verjetja: $P(x|y) = \frac{zamenjava[x_i,y_i]}{\text{število}(y_i)}$.
- $zamenjava[x_i, y_i]$ je število, kolikokrat je črka x_i v korpusu zamenjana s črko y_i in število(y_i) je število pojavitev črke y_i v korpusu.
- Kakšna je enačba za $P(x|y)$, če uporabimo glajenje add-1 v primeru zamenjave?
- Upoštevajte, da so v korpusu uporabljene samo slovenske besede in znaki, in da ima slovar V besed.

Naloga

- $\frac{zamenjava[x_i,y_i]}{\text{število}(x_i,y_i)}$
- $\frac{zamenjava[x_i,y_i]+1}{\text{število}(y_i)+V}$
- $\frac{zamenjava[x_i,y_i]+1}{\text{število}(y_i)+25}$
- $\frac{zamenjava[x_i,y_i]+1}{\text{število}(y_i)*V}$
- $\frac{zamenjava[x_i,y_i]+1}{\text{število}(y_i)+50}$

Naloga

- ☐ $\frac{zamenjava[x_i,y_i]}{število(x_i,y_i)}$ ✘
- ☐ $\frac{zamenjava[x_i,y_i]+1}{število(y_i)+V}$ ✘
- ☐ $\frac{zamenjava[x_i,y_i]+1}{število(y_i)+25}$ ✘
- ☐ $\frac{zamenjava[x_i,y_i]+1}{število(y_i)*V}$ ✘
- ☐ $\frac{zamenjava[x_i,y_i]+1}{število(y_i)+50}$ ✔

Naloga

- Recimo, da imamo naslednje verjetnosti besed v besedilih za ocenjevanje filmov:

	poz	neg
mi	0,09	0,16
so	0,07	0,06
všeč	0,29	0,06
komedije	0,08	0,11

- Imamo naslednji stavek: **všeč so mi komedije.**
- Z uporabo metode Naïve Bayes in upoštevanjem, da sta verjetnosti posameznega razreda enaki, določite v kateri razred sodi podana poved.

Naloga

$$c_{NB} = \arg\max_{c_j \in C} P(c_j) \prod_{i \in \text{položaj}} P(x_i|c_j)$$

$$P(pos) = 0,5 \cdot 0,09 \cdot 0,07 \cdot 0,29 \cdot 0,08 = 7,308e-05$$

$$P(neg) = 0,5 \cdot 0,16 \cdot 0,06 \cdot 0,06 \cdot 0,11 = 3,168e-05$$

Poved je klasificirana kot pozitivna kritika.