



LOČITEV IZVOROV IN ANALIZA NEODVISNIH KOMPONENT


Source separation & Independent component analysis




Ocenjevanje izvorov iz njihovih linearnih mešanic




Izvori



Meritve/mešanice izvorov



Ocenjeni izvori



Matematična notacija

Danih naj bo M meritev (digitalnih signalov):

$$\mathbf{x}[n] = \begin{bmatrix} x_1[n] \\ x_2[n] \\ \vdots \\ x_M[n] \end{bmatrix} \quad n = 1, \dots, N$$

kjer je n vzorec signala.

Matematični model meritev:

$$\begin{aligned}x_1[n] &= a_{11}s_1[n] + a_{12}s_2[n] + a_{13}s_3[n] \\x_2[n] &= a_{21}s_1[n] + a_{22}s_2[n] + a_{23}s_3[n] \\x_3[n] &= a_{31}s_1[n] + a_{32}s_2[n] + a_{33}s_3[n]\end{aligned}\quad \rightarrow \quad \mathbf{x}[n] = \mathbf{As}[n]$$

takošnji mešalni model

meritve

$$\mathbf{x}[n] = \begin{bmatrix} x_1[n] \\ x_2[n] \\ x_3[n] \end{bmatrix}$$

izvori

$$\mathbf{s}[n] = \begin{bmatrix} s_1[n] \\ s_2[n] \\ s_3[n] \end{bmatrix}$$

mešalna matrika

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \\ \mathbf{a}_1 & \mathbf{a}_2 & \mathbf{a}_3 \end{bmatrix}$$

Mešalna matrika \mathbf{A} je konstantna

mešalni vektorji

Ločitev izvorov

$$s_1[n] = w_{11}x_1[n] + w_{12}x_2[n] + w_{13}x_3[n]$$

$$s_2[n] = w_{21}x_1[n] + w_{22}x_2[n] + w_{23}x_3[n]$$

$$s_3[n] = w_{31}x_1[n] + w_{32}x_2[n] + w_{33}x_3[n]$$

$$\mathbf{x}[n] = \begin{bmatrix} x_1[n] \\ x_2[n] \\ x_3[n] \end{bmatrix}$$

meritve

$$\mathbf{s}[n] = \begin{bmatrix} s_1[n] \\ s_2[n] \\ s_3[n] \end{bmatrix}$$

izvori

$$\mathbf{W} = \left[\begin{array}{ccc|c} w_{11} & w_{12} & w_{13} & \mathbf{w}_1^T \\ \hline w_{21} & w_{22} & w_{23} & \mathbf{w}_2^T \\ \hline w_{31} & w_{32} & w_{33} & \mathbf{w}_3^T \end{array} \right]$$

separacijska matrika

$$\mathbf{s}[n] = \mathbf{W}\mathbf{x}[n]$$

$$s_i[n] = \mathbf{w}_i^T \mathbf{x}[n]$$

Separacijska matrika \mathbf{W} je konstantna.
Idealno $\mathbf{A}\mathbf{W} = \mathbf{I}$

\mathbf{w}_i – separacijski vektor

Omejitve in nedoločenosti:

- Izvori so statistično neodvisni

$$p(s_1[n], s_2[n], \dots, s_K[n]) = p(s_1[n]) p(s_2[n]) \dots p(s_K[n])$$

skupna verjetnost verjetnost posameznega izvora




- Energije (variance) izvorov (matrike) ne moremo določiti

$$\forall \alpha_i \neq 0 \Rightarrow \mathbf{x}[n] = \sum_{i=1}^K \left(\frac{1}{\alpha_i} \mathbf{a}_i \right) (\alpha_i s_i[n])$$


- Vrstni red izvorov je neznan in nedoločljiv

$$\mathbf{x}[n] = (\mathbf{A}\mathbf{P}^{-1})\mathbf{P}\mathbf{s}[n] \quad \mathbf{P} \text{ je permutacijska matrika}$$


Primer 1: dve meritvi, enakomerna porazdelitev




Skupni vektorski prostor




Skupni vektorski prostor



Enakomerna porazdelitev




$$p(s_i) = \begin{cases} \frac{1}{2\sqrt{3}} & \text{če } |s_i| \leq \sqrt{3} \\ 0 & \text{drugače} \end{cases}$$



neodvisni izvori

$$\mathbf{A} = \begin{bmatrix} 3 & 10 \\ 10 & 3 \end{bmatrix}$$


$$\mathbf{x} = \mathbf{As}$$



Enakomerna porazdelitev




$$p(s_i) = \begin{cases} \frac{1}{2\sqrt{3}} & \text{če } |s_i| \leq \sqrt{3} \\ 0 & \text{drugače} \end{cases}$$



$$\mathbf{x} = \mathbf{As}$$

$$\mathbf{A} = \begin{bmatrix} 5 & 10 \\ 10 & 2 \end{bmatrix}$$




neodvisni izvori


vsaka pika je en
($s_1[n]$, $s_2[n]$) par

odvisne meritve

Enakomerna porazdelitev




$$p(s_i) = \begin{cases} \frac{1}{2\sqrt{3}} & \text{če } |s_i| \leq \sqrt{3} \\ 0 & \text{drugače} \end{cases}$$



neodvisni izvori


$$\mathbf{x} = \mathbf{As}$$

$$\mathbf{A} = \begin{bmatrix} 8 & 10 \\ 10 & 1 \end{bmatrix}$$




odvisne meritve

Laplacova porazdelitev




$$p(s_i) = \frac{1}{2} e^{-|x|}$$

$$\mathbf{A} = \begin{bmatrix} 5 & 10 \\ 10 & 2 \end{bmatrix}$$




neodvisni izvori

$$\mathbf{x} = \mathbf{As}$$




odvisne meritve

Gaussova porazelitev




$$p(s_i) = \frac{1}{\sigma\sqrt{2\pi}} e^{-(x-\mu)^2/2\sigma^2}$$



neodvisni izvori

$$\mathbf{x} = \mathbf{As}$$

$$\mathbf{A} = \begin{bmatrix} 5 & 10 \\ 10 & 2 \end{bmatrix}$$



odvisne meritve

Korelacijska matrika meritev $\mathbf{x}[n]$

$$\mathbf{C}_{\mathbf{x}} = \frac{1}{N-1} \sum_{n=1}^N \mathbf{x}[n] \mathbf{x}^T[n] = \begin{bmatrix} c(x_1, x_1) & c(x_1, x_2) & \cdots & c(x_1, x_M) \\ c(x_2, x_1) & c(x_2, x_2) & \cdots & c(x_2, x_M) \\ \vdots & \vdots & \ddots & \vdots \\ c(x_M, x_1) & c(x_M, x_2) & \cdots & c(x_M, x_M) \end{bmatrix}$$

$$\text{kjer je } c(x_i, x_j) = E(x_i \cdot x_j) = \frac{1}{N-1} \sum_{n=1}^N x_i[n] x_j[n]$$

- $c(x_i, x_i)$ meri varianco $x_i \rightarrow$ maksimiziraj $c(x_i, x_i)$
- $c(x_i, x_j)$ meri korelacijsko med x_i in $x_j \rightarrow$ minimiziraj $c(x_i, x_j)$

Analiza PCA

- Najdi takšno ortonormalno transformacijsko matriko \mathbf{P} da bo $\mathbf{y}[n] = \mathbf{Px}[n]$ in bo

$$\mathbf{C}_y = \frac{1}{N-1} \sum_{n=1}^N \mathbf{y}^T[n] \mathbf{y}[n]$$

diagonalna matrika.

- Z drugimi besedami,
 - maksimiziraj $c(y_i, y_i)$
 - minimiziraj $c(y_i, y_j) \quad i \neq j$

Linearna transformacija P

- C_x je simetrična matrika. Diagonalizira jo ortonormalna matrika njenih lastnih vektorjev (E):

$$C_x = EDE^T$$

kjer je:

- D diagonalna matrika lastnih vrednosti λ_i matrike C_x . Brez izbube splošnosti lahko privzamemo, da so lastne vrednosti $\lambda_i = D[i,i]$ urejene v padajočem vrstnem redu.

$$\lambda_1 \geq \lambda_2 \geq \lambda_3, \dots, \geq \lambda_M$$

- E je matrika ustreznih lastnih vektorjev matrike C_x (lastni vektorji so stolpci matrike E).

Linearna transformacija P


- Matematičen trik: izberi $P=E^T$

$$\begin{aligned} C_y &= PC_x P^T \\ &= E^T C_x E \\ &= E^T (E D E)^T E \\ &= (E^T E) D (E^T E) \\ &= D \end{aligned}$$


$$\ker E^{-1} = E^T$$

Neodvisne komponente & PCA

Enakomerna porazdelitev




mešanica izvorov




poglavitne komponente

Neodvisne komponente & PCA

Laplaceova porazdelitev




mešanica izvorov




poglavitne komponente

Neodvisne komponente & PCA

Normalna (Gaussova) porazdelitev



mešanica izvorov



poglavitne komponente

Nekoreliranost in prostorsko beljenje

- Pobeljene komponente:
 - so nekorelirane (tako kot pri PCA)
 - imajo varianco enako 1
- Beljenje je razširitev analize PCA:

PCA:

$$\mathbf{y}[n] = \mathbf{Px}[n]$$

$$\mathbf{P} = \mathbf{E}^T$$

Beljenje:

$$\mathbf{y}[n] = \mathbf{Vx}[n]$$

$$\mathbf{V} = \mathbf{D}^{-1/2}\mathbf{E}^T$$

$$\frac{1}{N} \sum_{n=1}^N \mathbf{x}[n]\mathbf{x}^T[n] = \mathbf{C}_x = \mathbf{EDE}^T$$

Beljenje je le polovica analize ICA

- po definiciji: $\mathbf{y}[n] = \mathbf{V}\mathbf{x}[n]$, $\mathbf{V} = \mathbf{D}^{-1/2}\mathbf{E}^T$

$$\begin{aligned}\mathbf{C}_y &= \mathbf{V}\mathbf{C}_x\mathbf{V}^T \\ &= (\mathbf{D}^{-1/2}\mathbf{E}^T)(\mathbf{E}\mathbf{D}\mathbf{E}^T)(\mathbf{E}\mathbf{D}^{-1/2}) \\ &= \mathbf{D}^{-1/2}(\mathbf{E}^T\mathbf{E})\mathbf{D}(\mathbf{E}^T\mathbf{E})\mathbf{D}^{-1/2} \\ &= \mathbf{I}\end{aligned}$$


za unitarno matriko \mathbf{U} imamo

$$\mathbf{z}[n] = \mathbf{U}\mathbf{y}[n] \Rightarrow \mathbf{C}_z = \mathbf{U}\mathbf{C}_y\mathbf{U}^T = \mathbf{U}\mathbf{U}^T = \mathbf{I}$$


(unitarna matrika \mathbf{U} ustreza rotaciji)

Beljenje je le polovica analize ICA

Enakomerna porazdelitev




mešanica izvorov




pobeljene meritve

Beljenje je le polovica analize ICA

Laplaceova porazdelitev




mešanica izvorov




pobeljene meritve

Beljenje je le polovica analize ICA

Normalna porazdelitev



mešanica izvorov



pobeljene meritve

Normalna (Gaussova) porazdelitev je invariantna na rotacijo, zato so izvori z normalno porazdelitvijo v analizi ICA prepovedani

ICA je več kot beljenje

- neodvisne naključne spremenljivke se vedno nekorelirane

$$E(y_1 y_2) = E(y_1) E(y_2)$$

matematično upanje (v praksi
povprečna vrednost)

- nekorelirane naključne spremenljivke niso nujno neodvisne


□ zgled: $(y_1, y_2) = \{(0,1), (0,-1), (1,0), (-1,0)\}$

- kriterij neodvisnosti:

$$E(f(y_1)f(y_2)) = E(f(y_1)) E(f(y_2))$$

kjer je $f(\cdot)$ katerakoli nelinearna funkcija (npr.
 $f(y)=y^2, f(y)=|y|$)

Nenormalnost je neodvisnost



Nenormalnost je neodvisnost

■ Centralni limitni teorem:

- porazdelitev vsote neodvisnih spremenljivk limitira h Gaussovi (normalni) porazdelitvi
- porazdelitev vsote neodvisnih spremenljivk

$$a_1 s_1 + a_2 s_2 + \dots + a_K s_K$$

postane najmanj Gaussova, ko je vsota natanko enaka enemu izmed izvorov s_i t.j., ko so vsi a_i razen enega enaki 0.

■ Ideja: *minimiziraj gaussovskost ocenjenega izvora*

$s_i = \mathbf{w}_i^T \mathbf{x}$, kjer je \mathbf{w}_i separacijski vektor, ki ga moramo določiti.

Merila negaussovskosti:


Špičatost (kurtosis)

$$kurt(s_i) = E\{s_i^4\} - 3(E\{s_i^2\})^2$$

- Špičatost je 0 za Gaussove naključne spremenljivke
- Če ima s varianco enako 1 ($E\{s^2\}=1$), potem je


$$kurt(s_i) = E\{s_i^4\} - 3$$

Špičatost & gostota verjetnosti (PDF)




Špičatost & ločitev izvorov

Enakomerna
porazdelitev
amplitud
vzorcev izvorov




Vrednost špičatosti pri različnih
linearnih kombinacijah izvorov




Ker špičatost uporabimo za iskanje maksimumov in minimumov, lahko
izpustimo tudi odštevanje „-3“ in uporabimo samo $E\{s_i^4\}$

Špičatost & ločitev izvorov

Eksponentna
porazdelitev
amplitud
vzorcev izvorov




Vrednost špičatosti pri različnih
linearnih kombinacijah izvorov



Ker špičatost uporabimo za iskanje maksimumov in minimumov, lahko
izpustimo tudi odštevanje „-3“ in uporabimo samo $E\{s_i^4\}$


Gradientna optimizacija



$$\text{gradientna maksimizacija: } x = x + \frac{\Delta f(x)}{\Delta x}$$

$$\text{gradientna minimizacija: } x = x - \frac{\Delta f(x)}{\Delta x}$$

Gradientna maksimizacija




$$\text{gradientna maksimizacija: } x = x + \frac{\Delta f(x)}{\Delta x}$$

Pojasnite dolžino koraka ob vsakem skoku. Od česa je odvisna dolžina skoka?

Lokalni vs. globalni optimum?

Problem prevelikih korakov pri gradientni maksimizaciji




gradientna maksimizacija: $x = x + \alpha \frac{\Delta f(x)}{\Delta x}$ $\alpha > 1$

Pojasnite dolžino koraka ob vsakem skoku. Od česa je odvisna dolžina skoka?

Lokalni vs. globalni optimum?

Problem premajhnih korakov pri gradientni maksimizaciji



gradientna maksimizacija:
$$x = x + \alpha \frac{\Delta f(x)}{\Delta x} \quad \alpha \ll 1$$

Pojasnite dolžino koraka ob vsakem skoku. Od česa je odvisna dolžina skoka?

Lokalni vs. globalni optimum?

Gradientni pristop k optimizaciji: (\mathbf{x} – dve meritvi, trenutno ocenjujemo en izvor)

1. Inicializiramo ločitveni vektor: $\mathbf{w}_i = [1, 0]$

2. Rekonstruiramo i-ti izvor s_i : $s_i(n) = \mathbf{w}_i^T \mathbf{x}(n)$

3. Osvežimo ločitveni vektor: $\mathbf{w}_i = \mathbf{w}_i + \alpha \frac{\partial f(s_i(n))}{\partial \mathbf{w}_i}$

4. Normaliziramo ločitveni vektor: $\mathbf{w}_i = \frac{\mathbf{w}_i}{\|\mathbf{w}_i\|}$
(da preprečimo trivialno rešitev $\mathbf{w}_i = \mathbf{0}$)

$f(s_i(n))$ - skalarna meritna funkcija, npr. *kurt*

optimizacija

Gradientni pristop k optimizaciji: špičatost (zanemarimo -3 v enačbi špičatosti)

$$f(s_i) = E\{s_i^4\} = \frac{1}{N} \sum_n s_i^4[n]$$

$$s_i[n] = \mathbf{w}_i^T \mathbf{x}[n]$$

$$\frac{\partial f(s_i)}{\partial \mathbf{w}_i} = \frac{\partial f(s_i)}{\partial s_i} \frac{\partial s_i}{\partial \mathbf{w}_i} = 4E\{s_i^3 \mathbf{x}\}$$

$$= 4 \frac{1}{N} \sum_n s_i^3[n] \mathbf{x}[n]$$

2. Osvežimo ločitveni vektor: $\mathbf{w}_i = \mathbf{w}_i + \alpha 4 \frac{1}{N} \sum_n (s_i^3[n] \cdot \mathbf{x}[n])$

Gradientni pristop k optimizaciji: špičatost (x – dve meritvi, trenutno ocenjujemo en izvor)

1. Inicializiramo ločitveni vektor: $\mathbf{w}_i = [1, 0]$

2. Rekonstruiramo i-ti izvor s_i : $s_i = \mathbf{w}_i^T \mathbf{x}$

3. Osvežimo ločitveni vektor: $\mathbf{w}_i = \mathbf{w}_i + \alpha 4 \frac{1}{N} \sum_n (s_i^3[n] \cdot \mathbf{x}[n])$

4. Normaliziramo ločitveni vektor:
(da preprečimo trivialno rešitev $\mathbf{w}_i = \mathbf{0}$)

$$\mathbf{w}_i = \frac{\mathbf{w}_i}{\|\mathbf{w}_i\|}$$

Iterativno ponavljamo korake 2-4, dokler se s_i spreminja

optimizacija

Primer predstavljene gradientne optimizacije:



<http://research.ics.tkk.fi/ica/fastica/>

Praktične opombe

- Predobdelava s filtriranjem je dovoljena!
 - filtriranje ohranja mešalni model (mešalno matriko)
 - zmanjša šum
- Predobdelava z analizo PCA je dovoljena!
 - zmanjša dimenzijo problema (odstrani nepotrebne meritve)
 - zmanjša šum
- Izbira algoritma ICA:
 - sočasna ocenitev vseh izvorov vs. sekvenčna ocenitev posameznih izvorov
 - izbira kriterijske (optimizacijske) funkcije: špičatost, negentropija, Kullback–Leiblerjeva divergenca, maxinfo,...
 - realnočasovna vs. paketna ločitev izvorov

Ločitev izvorov z uporabo časovne strukture

- osnovna premla analize ICA

$$\forall \Delta n; E\{\mathbf{x}[n]\mathbf{x}^T[n + \Delta n]\} = 0$$

$$\forall \Delta n; E\{\mathbf{x}[n]\mathbf{x}^T[n]\} = E\{\mathbf{x}[n + \Delta n]\mathbf{x}^T[n + \Delta n]\}$$

- signali navadno vsebujejo več strukture kot naključne spremenljivke

- ločitev s pomočjo avtokovariance:

$$E\{\mathbf{x}[n]\mathbf{x}^T[n + \Delta n]\} \neq 0$$

- ločitev s pomočjo nestacionarnosti:


$$E\{\mathbf{x}[n]\mathbf{x}^T[n]\} \neq E\{\mathbf{x}[n + \Delta n]\mathbf{x}^T[n + \Delta n]\}$$

Primer ločitve izvorov s pomočjo avtokovariance:

SOBI

dostopen v sklopu

EEGLAB



<http://sccn.ucsd.edu/eeglab/>


Študijski material:

- Aapo Hyvärinen and Erkki Oja: Independent Component Analysis: A Tutorial
http://www.cis.hut.fi/aapo/papers/IJCNN99_tutorialweb/
(zelo nazorno učno gradivo pionirjev analize ICA)
- fastICA: <http://www.cis.hut.fi/projects/ica/fastica/>
(prostodostopeno orodje fastICA)
- J. F. Cardoso: ICA
<http://www.tsi.enst.fr/~cardoso/guidesepsou.html>
(spletna stran J. F. Cardosa, pionirja analize ICA)

PRIMERI IZ LITERATURE:

ICA APPLICATIONS: BIOMEDICAL SIGNALS

Možganski centri in njihovi prispevki k EEG



Brainmusic: fmri into musical sound

LISTENING TO THE DYNAMIC BRAIN

<http://www.youtube.com/watch?v=FX19mNKoXeo&feature=related>

Acoustic Blind Source Separation

<http://www.youtube.com/watch?v=Qr74sM7oqQc&feature=related>

Acoustic Blind Source Separation

<http://www.youtube.com/watch?v=b2TTxe25Om0>

Visual Blind Source Separation

<http://cnx.org/content/m15640/latest/>

Two-dimensional deconvolution

http://www.cs.technion.ac.il/~mbron/research_bss.html